



Faculté des Sciences et Techniques (**FST**)

Rapport de stage de fin d'études :

**Détection de la pneumonie dans les images radiographiques A l'aide de
l'apprentissage profond (Deep Learning).**

Réalisé par :

Elbou Aly Sidina : C20851

A la ministère de la transition numérique, de l'innovation et de la modernisation de
l'administration.

Spécialité :

Méthodes Informatiques Appliquées A la Gestion Des Entreprises (MIAGE)

Encadré par :

Dr. Benany, Encadrant Académique

Md. Fatimetou Abdou, Encadrante Professionnelle

Année Universitaire : 2023-2024

28 Mars, 2024

Résumé

Ce rapport décrit le développement d'une solution d'intelligence artificielle appliquée à la médecine pour la détection de la pneumonie dans les images radiographiques. Cette solution a été développée en utilisant des technologies telles que TensorFlow, des réseaux de neurones convolutionnels (CNN), HTML5, CSS3, JavaScript, etc.

Ce rapport présente les objectifs du projet, les méthodes et les approches utilisées pour le développement de la solution d'intelligence artificielle dédiée à la détection de la pneumonie dans les images radiographiques. Les résultats du projet ont démontré que la solution développée répondait aux besoins médicaux en matière de détection précise de la pneumonie. Les principales fonctionnalités de la solution comprennent l'acquisition et la gestion des images radiographiques, l'analyse par des algorithmes de deep Learning pour la détection de la pneumonie, le suivi des résultats et la génération de rapports pour les professionnels de la santé.

Ce rapport présente également les défis et obstacles rencontrés lors du développement de la solution d'intelligence artificielle pour la détection de la pneumonie dans les images radiographiques, ainsi que les solutions proposées pour surmonter ces obstacles.

Enfin, ce rapport conclut sur l'importance de cette solution d'intelligence artificielle pour la détection de la pneumonie dans les images radiographiques, mettant en avant ses implications cruciales dans le domaine médical. Il souligne également les perspectives futures d'amélioration de la solution, avec l'espoir qu'elle bénéficiera à la pratique médicale et pourra inspirer de futurs développements dans le domaine de la détection précoce des maladies.

Dédications :

Nous dédions ce projet à toutes les personnes touchées par la pneumonie, ainsi qu'à ceux qui ont lutté contre cette maladie. Leur courage et leur résilience nous inspirent dans notre quête de développer des solutions médicales innovantes pour améliorer la santé et le bien-être de chacun.

Nous souhaitons également dédier ce projet à nos amis et à nos encadrants, qui ont été une source constante de soutien et d'encouragement. Leur présence et leur confiance en nous ont été précieuses tout au long de ce parcours. Pour conclure, nous dédions mutuellement ce projet l'un à l'autre.

La collaboration a été une expérience remarquable et nous sommes fiers des réalisations que nous avons accomplies ensemble. Notre partenariat illustre la force de la coopération, de l'engagement et de la persévérance. Nous exprimons notre gratitude à tous ceux qui nous ont soutenus tout au long de ce périple. Ce projet vous est dédié.

Remerciements :

Au nom de toute l'équipe impliquée dans notre projet, je tiens à exprimer ma plus sincère gratitude envers vous pour votre soutien indéfectible tout au long de notre parcours. Votre accueil chaleureux et votre engagement envers notre projet ont été véritablement inspirants.

Je souhaite tout particulièrement remercier le Professeur Benany pour son expertise inestimable, ses conseils éclairés et son assistance constante. Sa présence et son soutien ont été des éléments essentiels dans la réussite de notre projet.

Un immense merci également à Fatimetou, ma superviseuse au sein du Ministère, pour sa guidance précieuse, sa disponibilité et son dévouement sans faille. Ses conseils avisés et son soutien ont grandement contribué à notre progression et à notre réussite.

Votre contribution a été inestimable et nous sommes profondément reconnaissants de vous avoir eu à nos côtés tout au long de cette aventure. Votre soutien a été un véritable moteur de notre succès et nous vous en sommes infiniment reconnaissants.

Avec toute notre gratitude et notre respect,

Sommaire :

Table des matières

Contents

Introduction Générale :	9
Chapitre I :	11
Présentation Générale	11
I.1 Introduction	11
I.2 Cadre Général	11
I.3 Contexte de la pneumonie et de sa détection	11
I.4 Motivation pour l'utilisation du Deep Learning :	12
I.4.1 Capacité à Extraire des Caractéristiques Abstraites :	12
I.4.2 Adaptabilité aux Données Complexes :	12
I.4.3 Performance Améliorée :	13
I.4.4 Automatisation du Processus de Diagnostic :	13
I.5 Problématique :	13
I.5.1 Variabilité et Complexité des Images Radiographiques :	13
I.5.2 Disponibilité Limitée de Données Annotées :	13
I.5.3 Interprétabilité des Modèles de Deep Learning :	14
I.5.4 Considérations Éthiques et Réglementaires :	14
I.5.5 Conclusion :	14
I.6 Objectif du rapport :	15
I.6.1 Développer un Modèle de Deep Learning Performant :	15
I.6.2 Optimiser la Sensibilité et la Spécificité du Modèle :	15
I.6.3 Assurer la Généralisabilité et la Robustesse du Modèle :	15
I.6.4 Faciliter l'Intégration Clinique du Modèle :	15
I.6.5 Explorer les Implications Éthiques et Réglementaires :	16
I.7 Conclusion :	16
Chapitre II :	17
Introduction à l'intelligence artificielle	17
II.1 Définition de l'intelligence artificielle :	17

II.2 Evolution historique de l'IA :	18
II.2.1 Les origines de l'intelligence artificielle : Turing et les machines logiques	18
II.2.2 l'essor de l'intelligence artificielle : des chercheurs audacieux et des défis mémorables	19
II.2.3 Ou en est l'intelligence artificielle aujourd'hui :	19
II.3 Impacts Socio-économique de l'intelligence artificielle :	20
II.4 Application de l'IA dans différents domaines :	22
II.5 Défis et Opportunités pour l'Avenir de l'IA :	27
Chapitre III :	30
Exploration des méthodes de détection de la pneumonie	30
III.1 Introduction :	30
III.2 Etat de l'art de la détection de la pneumonie :	30
III.2.1 Méthodes traditionnelles de détection de la pneumonie :	30
III.2.2 Innovations récentes de détection de la pneumonie :	31
Chapitre IV :	33
Apprentissage automatique	33
IV.1 Concepts de base de machine learning :	33
IV.1.1 Algorithmes de Machine Learning :	33
IV.1.2 Enjeux et défis du machine learning :	34
IV.2 Types d'apprentissage (Supervisé – non Supervisé – Sémi Supervisé) :	35
IV.2.1 Apprentissage Supervisé :	35
IV.2.2 Apprentissage Non Supervisé :	37
IV.3 Applications du Machine Learning dans différents domaines :	39
Chapitre V :	41
Apprentissage Profond	41
V.1 Introduction aux réseaux de neurones :	41
V.2 Avancées récentes et Applications du Deep Learning :	43
Chapitre VI :	45
Vision par Ordinateur	45
VI.1 Principes de base de la vision par ordinateur :	45
VI.2 Traitement des images médicales :	46
VI.3 Techniques de Pré-Traitement et de Post-Traitement des Données :	47
Chapitre VII :	49
Etude de cas :	49
(Détection de la pneumonie A l'aide de l'apprentissage profond.)	49

VII.1 Collecte et pré-traitement des données :	49
VII.2 Conception de l'architecture du réseau neuronal :	50
VII.3 Entraînement du modèle et évaluation des performances :	51
VII.4 Présentation des résultats obtenus par le modèle :	52
Chapitre VIII :	54
Conception de l'application.....	54
VIII.1 Introduction :	54
VIII.2 Etude des besoins :	54
VIII.3 Diagramme de cas d'utilisation :	56
VIII.4 Diagramme de Séquence :	57
VIII.5 Diagramme d'activité :	57
VIII.6 Diagramme de classes :	58
VIII.7 Conclusion :	59
Chapitre IX :	60
Réalisation de l'application	60
IX.1 Introduction :	60
IX.2 Environnement du développement :	60
IX.2.1 Environnement matériel :	60
IX.2.2 Environnement logiciel :	60
Conclusion Générale :	67

Listes Des Figures :

Figure 1: Organigramme de la ministère.	11
Figure 2: Schéma représentatif.	14
Figure 3: Alan Turing.	18
Figure 4: Deep Learning.	19
Figure 5 : Diagnostic médical Assisté par l'IA.	22
Figure 6: Assistance personnalisée.	23
Figure 7: Assistance de l'apprentissage en ligne.	24
Figure 8: Chatbot.	24
Figure 9:Industrie.	25
Figure 10: Voiture autonome.	26
Figure 11: Drone de l'agriculture.	27
Figure 12: image du thorax.	31
Figure 13 : Images du Dataset.	46
Figure 14: Exemples du dataset. (a) cas normaux.	49
Figure 15: Exemples du dataset. (b) cas anormaux.	50
Figure 16 : tableau.	50
Figure 17: Architecture CNN.	51
Figure 18 : Graphiques des résultats.	52
Figure 19: Matrice de confusion.	53
Figure 20: Diagramme de cas d'utilisation.	56
Figure 21: Diagramme de Séquence.	57
Figure 22: Diagramme d'activité.	58
Figure 23: Diagramme de classes.	59
Figure 24: VScode.	60
Figure 25: Google Colab.	61
Figure 26: HTML.	61
Figure 27: CSS.	62
Figure 28: JAVASCRIPT.	62
Figure 29: Flask.	63
Figure 30: Tensorflow.	64
Figure 31: page de connexion.	65
Figure 32: page principale.	65
Figure 33: télécharger des images.	66
Figure 34:page résultat.	66

Listes Des Abréviation :

CNN : Convolutionnal neural network.

CPU : Central Processing Unit.

CSS : Cascading Style Sheets.

FST : Faculté Des Sciences Et Techniques.

MIAGE : Méthodes Informatiques Appliquées A la Gestion Des Entreprises.

HTML : HyperText Markup Language.

RAM : Random-Access Memory.

UML : Unified Modeling Language.

VSCode : Visual Studio Code.

Introduction Générale :

Dans le cadre de notre troisième année de licence à la Faculté des sciences et techniques FST, MIAGE, on a eu l'opportunité de réaliser un stage de 8 semaines au sein du Ministère de la transition numérique, plus précisément à la direction de l'équipe de développement durant lequel on a réalisé un modèle IA(Intelligence Artificielle) basé sur le Deep Learning développée par plusieurs technologies et Framework notamment *Tensorflow* , réseaux de neurones convolutionnelles visant à éviter les erreurs courantes de la diagnostic et améliorer la précision, rapidité du diagnostic et la qualité de service du support.

Ce rapport est constitué de neufs Chapitres :

Chapitre 1 :

Dans le premier chapitre, nous verrons une présentation générale, dans laquelle nous mettons l'accent sur le champ d'étude de notre application qui est le suivi du plan d'action. Nous justifions après le choix de la méthodologie du développement.

Chapitre 2 :

L'introduction de ce chapitre pose les fondations en définissant l'intelligence artificielle (IA) et en exposant ses divers aspects et champs d'application. Ensuite, une exploration de l'évolution de l'IA depuis ses origines jusqu'à son état actuel met en évidence les progrès significatifs, les moments déterminants, et les contributions essentielles qui ont influencé son développement.

Chapitre 3 :

Une revue complète de l'état actuel des techniques de détection de la pneumonie. Cela comprend les méthodes traditionnelles et les avancées récentes dans le domaine. Cette section se concentre sur les techniques traditionnelles utilisées pour détecter la pneumonie à partir d'images radiographiques. Elle examine les approches classiques et leurs applications pratiques. Enfin, les limitations des méthodes traditionnelles de détection de la pneumonie sont discutées.

Chapitre 4 :

Ce chapitre introduit les concepts fondamentaux du Machine Learning, incluant les types d'apprentissage (supervisé, non supervisé, renforcement) et explore leurs applications pratiques dans divers domaines. Il offre ainsi une base compréhensive pour aborder le sujet du Machine Learning et son utilisation dans des contextes réels.

Chapitre 5 :

Ce chapitre explore les bases des réseaux de neurones et leur architecture profonde, en mettant particulièrement l'accent sur les CNN. Il examine également les avancées récentes et les diverses applications du Deep Learning, offrant ainsi une vue d'ensemble complète de ce domaine en constante évolution.

Chapitre 6 :

Ce chapitre présente les concepts fondamentaux de la vision par ordinateur, ainsi que son application spécifique dans le traitement d'images médicales, mettant en lumière les techniques de prétraitement et de post-traitement des images radiographiques. Il offre ainsi un aperçu complet de l'utilisation de la vision par ordinateur dans le domaine médical, en mettant en évidence les méthodes clés de traitement d'images.

Chapitre 7 :

Ce chapitre décrit le processus de détection de la pneumonie en utilisant l'apprentissage profond, en commençant par la collecte et le prétraitement des données, puis en détaillant la conception de l'architecture du réseau neuronal. Il poursuit en présentant le processus d'entraînement du modèle et l'évaluation de ses performances, avant de conclure par la présentation des résultats obtenus par le modèle, offrant ainsi un aperçu complet de l'application de l'apprentissage profond à cette étude de cas spécifique.

Chapitre 8 :

Le chapitre présente la conception de l'application, débutant par une introduction générale, suivie du Cahier de charge et par la représentation des cas d'utilisation à l'aide d'un diagramme, puis l'illustration du flux des interactions à travers un diagramme de séquences. Ensuite, il détaille la structure et les relations entre les différentes classes de l'application à travers un diagramme de classes, et enfin, il décrit le déploiement de l'application à travers un diagramme dédié. Le chapitre se termine par une conclusion, fournissant ainsi un aperçu complet du processus de conception de l'application.

Chapitre 9 :

Le chapitre sur la réalisation de l'application commence par une introduction, suivie d'une description de l'environnement de développement, incluant à la fois l'aspect matériel et logiciel. Il détaille également les interfaces graphiques utilisées dans l'application, fournissant ainsi une vue d'ensemble complète du processus de création de l'application, depuis son environnement de développement jusqu'à son interface utilisateur.

Chapitre I :

Présentation Générale

I.1 Introduction

Le premier chapitre du rapport débute en fournissant une vue d'ensemble, servant ainsi de porte d'entrée pour les lecteurs. Il expose le cadre du stage ainsi que l'organisation dans laquelle celui-ci s'est déroulé. Ensuite, il aborde le sujet spécifique du stage, suivi d'une justification détaillée du choix méthodologique adopté.

I.2 Cadre Général

Dans le cadre de notre troisième année de licence à la Faculté des sciences et techniques FST, MIAGE, on a eu l'opportunité de réaliser un stage de 8 semaines au sein de la ministère de la transition, plus précisément à la direction de l'équipe de développement, durant lequel on a réalisé un modèle de détection de la pneumonie dans les images radiographiques A l'aide de l'apprentissage profond(Deep Learning) intégré dans une application web visant à éviter les erreurs de diagnostic humain, à accroître la précision et l'efficacité du dépistage de la maladie et à faciliter un traitement plus rapide et plus efficace.



Figure 1: Organigramme de la ministère.

I.3 Contexte de la pneumonie et de sa détection

Dans le domaine de la médecine, la pneumonie représente une condition respiratoire aiguë caractérisée par une inflammation des sacs alvéolaires des poumons, souvent provoquée par une infection bactérienne, virale ou fongique. Cette affection constitue un défi clinique majeur en raison de sa prévalence élevée, de sa variabilité clinique et de sa capacité à affecter des individus de tous âges, en particulier les nourrissons, les personnes âgées et les individus immunodéprimés. La détection précoce et précise de la pneumonie revêt une importance capitale pour initier un traitement rapide et approprié, réduisant ainsi le risque de complications graves et de décès.

Traditionnellement, le diagnostic de la pneumonie repose sur l'examen clinique, l'analyse des antécédents médicaux du patient, ainsi que sur l'imagerie radiographique, en particulier les radiographies pulmonaires. Cependant, l'interprétation des images radiographiques peut être sujette à des variations interprétatives entre les praticiens, entraînant des erreurs de diagnostic et des retards dans la prise en charge des patients. De plus, le processus de diagnostic manuel peut être chronophage et nécessite souvent l'expertise de radiologues spécialisés, limitant ainsi la disponibilité des services de diagnostic dans certaines régions.

Pour pallier ces défis, l'utilisation de l'apprentissage en profondeur, une branche de l'intelligence artificielle, émerge comme une approche prometteuse dans la détection automatisée de la pneumonie à partir d'images radiographiques. En exploitant des techniques avancées de traitement d'image et des réseaux de neurones convolutifs, les modèles d'apprentissage en profondeur peuvent être formés pour identifier les caractéristiques distinctives des opacités pulmonaires associées à la pneumonie, améliorant ainsi la sensibilité et la spécificité du diagnostic.

Dans ce contexte, le développement et la validation de modèles de détection de la pneumonie reposant sur l'apprentissage en profondeur offrent un potentiel considérable pour renforcer les capacités de dépistage précoce et précis de cette maladie respiratoire critique, ouvrant la voie à des interventions thérapeutiques plus rapides et efficaces, et potentiellement à une amélioration des résultats cliniques pour les patients.

I.4 Motivation pour l'utilisation du Deep Learning :

L'utilisation du deep Learning émerge comme une solution prometteuse dans divers domaines, motivée par ses capacités exceptionnelles à traiter de grandes quantités de données complexes et à extraire des modèles hautement abstraits et non linéaires. Dans le contexte de la détection de la pneumonie à partir d'images radiographiques, cette méthode trouve une justification convaincante en raison de plusieurs facteurs clés.

I.4.1 Capacité à Extraire des Caractéristiques Abstraites :

Les images radiographiques présentent une grande variabilité dans leur apparence en raison de facteurs tels que la position du patient, la qualité de l'image et la présence de comorbidités. Les méthodes traditionnelles de traitement d'image peuvent ne pas être suffisamment robustes pour extraire efficacement les caractéristiques pertinentes de ces images dans un cadre diagnostique. En revanche, les réseaux de neurones profonds peuvent apprendre de manière automatique et hiérarchique à représenter les caractéristiques discriminantes à partir des données brutes, permettant ainsi une adaptation efficace à cette variabilité inhérente des images radiographiques pulmonaires.

I.4.2 Adaptabilité aux Données Complexes :

Les ensembles de données médicales utilisés pour la détection de la pneumonie peuvent être vastes et comporter une grande diversité d'images provenant de différents centres médicaux et de

différentes populations de patients. Le deep Learning offre une flexibilité considérable pour traiter ces données complexes, en exploitant des architectures de réseaux neuronaux profonds capables de capturer des modèles complexes et des relations non linéaires entre les caractéristiques extraites des images radiographiques.

I.4.3 Performance Améliorée :

Les études récentes ont démontré que les modèles d'apprentissage en profondeur peuvent rivaliser, voire surpasser, les radiologues experts dans la détection de la pneumonie à partir d'images radiographiques. Cette performance améliorée est attribuable à la capacité des réseaux de neurones profonds à généraliser à partir de grands ensembles de données et à identifier des motifs subtils et complexes dans les images qui peuvent échapper à l'œil humain, permettant ainsi une détection plus précise et précoce de la maladie.

I.4.4 Automatisation du Processus de Diagnostic :

L'intégration de modèles d'apprentissage en profondeur dans les flux de travail cliniques peut permettre une automatisation partielle du processus de diagnostic de la pneumonie, en fournissant des outils d'aide à la décision aux professionnels de la santé. Cela peut conduire à une réduction du temps nécessaire pour établir un diagnostic, à une meilleure utilisation des ressources cliniques et à une augmentation de la rapidité de la prise en charge des patients, ce qui est particulièrement crucial dans les environnements médicaux à forte charge de travail.

I.5 Problématique :

La détection de la pneumonie à partir d'images radiographiques constitue un défi majeur dans le domaine médical, nécessitant des approches diagnostiques précises et fiables pour une prise en charge efficace des patients. L'émergence du deep learning comme méthode prometteuse pour aborder cette problématique soulève cependant plusieurs questions et défis à relever. Cette problématique se concentre sur l'exploration de ces défis et sur les stratégies pour les surmonter, en se basant sur une analyse approfondie des aspects techniques, cliniques et éthiques de l'utilisation du deep learning dans ce contexte.

I.5.1 Variabilité et Complexité des Images Radiographiques :

Les images radiographiques de patients atteints de pneumonie peuvent présenter une grande variabilité en termes de qualité, d'angle de vue et de présence d'artefacts. De plus, la pneumonie peut se manifester sous différentes formes, allant des opacités pulmonaires subtiles aux infiltrats étendus. Cette variabilité et cette complexité des images constituent un défi majeur pour les modèles de deep learning, qui doivent être capables de généraliser à partir d'un large éventail de conditions cliniques tout en évitant le surajustement aux caractéristiques spécifiques des ensembles de données d'entraînement.

I.5.2 Disponibilité Limitée de Données Annotées :

L'entraînement de modèles de deep learning nécessite des ensembles de données volumineux et annotés, ce qui peut poser problème dans le contexte de la détection de la pneumonie. Les images radiographiques doivent être annotées par des experts pour indiquer la présence ou l'absence de pneumonie, une tâche qui peut être fastidieuse et sujette à des variations interprétatives. De plus, les données annotées peuvent être limitées en quantité, en particulier pour les cas moins courants ou pour les populations spécifiques, ce qui peut compromettre la performance et la généralisabilité des modèles de deep learning.

I.5.3 Interprétabilité des Modèles de Deep Learning :

Bien que les modèles de deep learning puissent souvent atteindre des performances impressionnantes dans la détection de la pneumonie, leur opacité et leur manque d'interprétabilité peuvent poser des défis en matière de confiance et de validation clinique. Comprendre comment et pourquoi un modèle de deep learning prend une décision particulière peut être crucial pour son adoption et son utilisation clinique. Par conséquent, il est essentiel de développer des techniques pour expliquer les prédictions des modèles de deep learning et pour évaluer leur fiabilité et leur robustesse dans des scénarios cliniques réels.




Figure 2: Schéma représentatif.

I.5.4 Considérations Éthiques et Réglementaires :

L'intégration de modèles de deep learning dans les processus de diagnostic médical soulève des questions éthiques et réglementaires importantes. Les décisions prises par les modèles de deep learning peuvent avoir des implications importantes pour les patients, notamment en ce qui concerne les recommandations de traitement et les décisions cliniques. Il est donc crucial de garantir la confidentialité et la sécurité des données des patients, ainsi que de garantir la transparence et la responsabilité dans le développement et l'utilisation des modèles de deep learning en médecine.

I.5.5 Conclusion :

La détection de la pneumonie dans les images radiographiques à l'aide du deep learning présente des défis techniques, cliniques et éthiques importants. Cependant, en surmontant ces défis, les modèles de deep learning ont le potentiel de révolutionner le diagnostic et la prise en charge des patients atteints de pneumonie, en permettant une détection précoce et précise de la maladie et en facilitant une intervention thérapeutique rapide et efficace. Il est donc essentiel de poursuivre la recherche et le développement dans ce domaine, tout en tenant compte des considérations éthiques et réglementaires pour garantir une utilisation responsable et éthique de cette technologie dans la pratique clinique.

I.6 Objectif du rapport :

Le présent rapport vise à définir et à examiner les objectifs fondamentaux du projet de détection de la pneumonie dans les images radiographiques en utilisant le deep Learning. Ces objectifs sont soigneusement élaborés pour guider la recherche et le développement dans ce domaine crucial de la santé, en mettant l'accent sur la précision diagnostique, la fiabilité des modèles et leur applicabilité clinique. Voici une description détaillée des objectifs du rapport :

I.6.1 Développer un Modèle de Deep Learning Performant :

L'objectif principal de ce projet est de développer un modèle de deep learning capable de détecter efficacement la pneumonie à partir d'images radiographiques. Ce modèle devrait dépasser les performances des méthodes traditionnelles de diagnostic et démontrer une sensibilité et une spécificité élevées dans la détection des opacités pulmonaires associées à la pneumonie.

I.6.2 Optimiser la Sensibilité et la Spécificité du Modèle :

Un objectif essentiel est d'optimiser à la fois la sensibilité et la spécificité du modèle de deep learning. Il s'agit de minimiser les faux positifs et les faux négatifs, garantissant ainsi une détection précise de la pneumonie tout en réduisant les erreurs de diagnostic qui pourraient compromettre la qualité des soins aux patients.

I.6.3 Assurer la Généralisabilité et la Robustesse du Modèle :

Il est impératif que le modèle de deep learning soit capable de généraliser à différentes populations de patients, à différents centres médicaux et à différentes conditions d'imagerie. Cela nécessite des techniques de validation rigoureuses pour évaluer la robustesse du modèle et garantir sa fiabilité dans des situations cliniques diverses et variées.

I.6.4 Faciliter l'Intégration Clinique du Modèle :

Un objectif important est de faciliter l'intégration clinique du modèle de deep learning dans les flux de travail diagnostiques existants. Cela implique de développer des interfaces conviviales pour les cliniciens, des pipelines d'inférence rapides et efficaces, ainsi que des mécanismes de validation et de suivi pour assurer la qualité et la sécurité des décisions cliniques basées sur le modèle.

I.6.5 Explorer les Implications Éthiques et Réglementaires :

Enfin, un objectif transversal est d'explorer les implications éthiques et réglementaires de l'utilisation du deep learning dans la détection de la pneumonie. Cela comprend l'examen des questions de confidentialité des données, de responsabilité clinique, de transparence des modèles et de gouvernance réglementaire, afin de garantir une utilisation éthique et responsable de la technologie dans la pratique médicale. En somme, ce rapport vise à définir et à atteindre des objectifs ambitieux dans le domaine de la détection de la pneumonie à l'aide du deep learning, avec pour objectif ultime d'améliorer les résultats cliniques pour les patients, de faciliter le travail des cliniciens et de promouvoir une utilisation éthique et responsable de la technologie dans le domaine de la santé.

I.7 Conclusion :

Ce chapitre d'introduction offre une vue d'ensemble de notre rapport en présentant notre organisme d'accueil et en justifiant notre choix méthodologique. En mettant en lumière ces éléments dès le début, nous posons les bases nécessaires pour une compréhension approfondie de l'étude de l'existant et pour mettre en valeur l'intérêt et la pertinence de notre modèle dans les chapitres à venir.

Chapitre II :

Introduction à l'intelligence artificielle

II.1 Définition de l'intelligence artificielle :

Le terme « **intelligence artificielle** », créé par John McCarthy, est souvent abrégé par le sigle « IA » (ou « AI » en anglais, pour **artificial intelligence**). McCarthy définit l'IA ainsi : « C'est la science et l'ingénierie de la fabrication de machines intelligentes, en particulier de programmes informatiques intelligents. Elle est liée à la tâche similaire qui consiste à utiliser des ordinateurs pour comprendre l'intelligence humaine, mais l'IA ne doit pas se limiter aux méthodes qui sont biologiquement observables. »

Elle est également définie par l'un de ses créateurs, Marvin Lee Minsky, comme « la construction de programmes informatiques qui s'adonnent à des tâches qui sont, pour l'instant, accomplies de façon plus satisfaisante par des êtres humains car elles demandent des processus mentaux de haut niveau tels que : l'apprentissage perceptuel, l'organisation de la mémoire et le raisonnement critique ». On y trouve donc le côté « artificiel » atteint par l'usage des ordinateurs ou de processus électroniques élaborés et le côté « intelligence » associé à son but d'imiter le comportement. Cette imitation peut se faire dans le raisonnement, par exemple dans les jeux ou la pratique des mathématiques, dans la compréhension des langues naturelles, dans la perception : visuelle (interprétation des images et des scènes), auditive (compréhension du langage parlé) ou par d'autres capteurs, dans la commande d'un robot dans un milieu inconnu ou hostile.

Même si elles respectent globalement la définition de Minsky, certaines définitions de l'IA varient sur deux points fondamentaux :

- Les définitions qui lient l'IA à un aspect *humain* de l'intelligence, et celles qui la lient à un modèle idéal d'intelligence, non forcément humaine, nommée rationalité ;
- Les définitions qui insistent sur le fait que l'IA a pour but d'avoir *toutes les apparences* de l'intelligence (humaine ou rationnelle), et celles qui insistent sur le fait que le *fonctionnement interne* du système d'IA doit ressembler également à celui de l'être humain et être au moins aussi rationnel

Il y a une confusion fréquente dans le débat public entre intelligence artificielle, apprentissage automatique (*machine Learning*) et apprentissage profond (*deep learning*). Pourtant, ces notions ne sont pas équivalentes, mais imbriquées. L'intelligence artificielle englobe l'apprentissage automatique, qui lui-même englobe l'apprentissage profond.

II.2 Evolution historique de l'IA :

L'évolution historique de l'intelligence artificielle (IA) représente un voyage fascinant à travers les décennies, marqué par des avancées scientifiques, des innovations technologiques, et des réflexions philosophiques profondes. L'IA, aujourd'hui omniprésente dans divers domaines allant de la médecine à l'industrie, a des racines qui plongent dans l'Antiquité, où les premières notions de machines et d'automates ont été envisagées par des penseurs tels qu'Aristote et Héron d'Alexandrie. Cependant, c'est au milieu du XXe siècle que l'intelligence artificielle a véritablement émergé en tant que discipline scientifique, grâce à des pionniers comme Alan Turing et John McCarthy, qui ont posé les bases théoriques et techniques de ce domaine.

II.2.1 Les origines de l'intelligence artificielle : Turing et les machines logiques

Quelles sont les origines de l'intelligence artificielle ? L'histoire de l'IA remonte aux années 1940, avec le mathématicien et logicien Alan **Turing**. Il est souvent considéré comme le père de l'intelligence artificielle grâce à sa machine de Turing, qui est un modèle théorique de calcul. Cependant, à l'époque, l'idée de machines pensantes était souvent accueillie avec peur. Les gens craignaient que ces machines ne prennent le contrôle, posant un **danger** mortel. Turing, cependant, était convaincu que les machines pourraient être programmées pour reproduire l'intelligence humaine.




Figure 3: Alan Turing.

L'histoire de l'IA peut être divisée en plusieurs phases distinctes, chacune caractérisée par des percées technologiques et des paradigmes de recherche spécifiques. Les premières décennies ont été dominées par l'enthousiasme pour la résolution de problèmes et la logique symbolique, illustrées par des programmes capables de jouer aux échecs ou de résoudre des théorèmes mathématiques.

II.2.2 L'essor de l'intelligence artificielle : des chercheurs audacieux et des défis mémorables

Au cours des années 1950 et 1960, l'intelligence artificielle a connu un développement rapide. Les chercheurs ont commencé à créer des programmes capables de résoudre des problèmes et de jouer à des jeux tels que les échecs. C'était un moment **fantastique** où les chercheurs étaient prêts à relever d'énormes **défis**. Les premiers programmes d'IA étaient relativement **faibles** et faisaient des **erreurs**, mais ils ont ouvert la voie à des avancées majeures.

Le renouveau de l'IA dans les années 1980 et 1990 a été catalysé par des progrès en matière de puissance de calcul et par des approches comme les réseaux de neurones artificiels, qui ont tenté de mimer les processus cognitifs humains. L'émergence du machine learning et de l'apprentissage profond au début du XXIe siècle a radicalement transformé le paysage de l'IA, permettant des applications pratiques jusque-là inimaginables, telles que la reconnaissance vocale, la vision par ordinateur, et la compréhension du langage naturel.



Figure 4: Deep Learning.

II.2.3 Ou en est l'intelligence artificielle aujourd'hui :

L'intelligence artificielle d'aujourd'hui est à un stade avancé et révolutionnaire. Elle est capable de traiter et d'analyser des quantités massives de données en un temps record. Les modèles d'apprentissage automatique sont de plus en plus sophistiqués et intelligents. Cependant, il est important de ne pas tomber dans la paresse intellectuelle et de continuer à questionner et à comprendre comment ces systèmes fonctionnent. L'IA est également devenue un sujet de vanité pour certaines entreprises et pays, qui cherchent à être à la pointe de cette technologie. Cela a conduit à une course mondiale pour développer l'IA la plus avancée.

II.3 Impacts Socio-économique de l'intelligence artificielle :

L'intelligence artificielle (IA) a émergé comme une force transformatrice au sein de la société contemporaine, modifiant profondément les structures économiques et sociales. Cette technologie, qui englobe des domaines tels que l'apprentissage automatique, le traitement du langage naturel et la robotique, révolutionne divers secteurs d'activité. L'analyse des impacts socio-économiques de l'IA est essentielle pour comprendre les changements actuels et anticiper les défis futurs.

Transformation des Marchés du Travail

Création et Destruction d'Emplois :

L'une des conséquences les plus visibles de l'IA est la transformation des marchés du travail. L'automatisation et l'IA ont le potentiel de remplacer des tâches répétitives et routinières, conduisant à une destruction d'emplois dans certains secteurs, notamment la manufacture et les services de faible qualification. Par exemple, les caisses automatiques dans les supermarchés et les robots de fabrication dans les usines remplacent progressivement les travailleurs humains. Cependant, l'IA génère également de nouveaux emplois, particulièrement dans les domaines liés à la technologie, comme le développement de logiciels, la maintenance de systèmes d'IA et la cybersécurité. En outre, des secteurs entiers peuvent émerger, stimulés par l'innovation technologique et les nouvelles possibilités offertes par l'IA.

Changement des Compétences Requises :

Avec l'avènement de l'IA, la demande en compétences évolue. Les compétences techniques, telles que la programmation, la gestion de données et la compréhension des algorithmes d'IA, deviennent cruciales. Parallèlement, les compétences non techniques, comme la pensée critique, la résolution de problèmes complexes et la créativité, gagnent en importance car elles sont plus difficiles à automatiser. Ce changement nécessite une adaptation rapide des systèmes éducatifs et des programmes de formation continue pour préparer la main-d'œuvre future.

Impacts Économiques

Productivité et Croissance Économique :

L'IA a le potentiel d'augmenter significativement la productivité. Les algorithmes d'apprentissage automatique peuvent analyser des quantités massives de données plus rapidement et plus précisément que les humains, améliorant ainsi l'efficacité opérationnelle et la prise de décision dans les entreprises. Cette augmentation de la productivité peut stimuler la croissance économique, en permettant une production accrue avec des ressources équivalentes ou moindres.

Inégalités Économiques :

Malgré ses bénéfices potentiels, l'IA peut exacerber les inégalités économiques. Les gains de productivité générés par l'IA tendent à se concentrer dans les mains des entreprises technologiques et des individus possédant les compétences nécessaires pour travailler avec ces technologies. Cela peut entraîner une concentration accrue de la richesse et un élargissement du fossé entre les travailleurs qualifiés et non qualifiés. Les politiques publiques doivent donc s'adapter pour redistribuer équitablement les bénéfices économiques de l'IA et atténuer les disparités.

Impacts Sociaux

Qualité de Vie et Bien-être :

L'IA a le potentiel d'améliorer la qualité de vie en offrant des solutions innovantes dans des domaines tels que la santé, l'éducation et les services publics. Par exemple, les diagnostics médicaux assistés par l'IA peuvent améliorer la précision et la rapidité des traitements, tandis que les systèmes éducatifs personnalisés peuvent offrir des expériences d'apprentissage adaptées aux besoins individuels des étudiants.

Défis Éthiques et de Gouvernance :

L'utilisation de l'IA soulève également des questions éthiques et de gouvernance. Les algorithmes peuvent perpétuer ou amplifier des biais existants si les données d'apprentissage sont biaisées. De plus, l'IA pose des défis en termes de confidentialité et de sécurité des données. Il est crucial de développer des cadres réglementaires robustes pour garantir une utilisation éthique et équitable de l'IA, ainsi que pour protéger les droits individuels.

Conclusion

L'intelligence artificielle est un moteur puissant de transformation socio-économique. Ses impacts sur le marché du travail, la croissance économique, les inégalités et la qualité de vie sont significatifs et multiformes. Alors que l'IA continue de se développer, il est essentiel d'anticiper et de gérer ses effets pour maximiser les bénéfices tout en minimisant les risques. Les politiques publiques, l'éducation et la recherche doivent jouer un rôle central pour assurer une transition harmonieuse vers une société intégrant pleinement l'intelligence artificielle.

II.4 Application de l'IA dans différents domaines :

Introduction

L'intelligence artificielle (IA) s'est imposée comme une technologie omniprésente, révolutionnant divers secteurs par ses capacités d'apprentissage automatique, de traitement du langage naturel et de vision par ordinateur. Ses applications sont vastes et variées, touchant aussi bien la médecine que les finances, l'éducation, l'industrie et bien d'autres domaines. Cet essai vise à explorer en détail les applications de l'IA dans plusieurs secteurs clés, en mettant en lumière les transformations et les innovations qu'elle engendre

Médecine

Diagnostics et Traitements Personnalisés :

L'un des domaines les plus prometteurs pour l'IA est la médecine. Les algorithmes d'apprentissage automatique peuvent analyser des images médicales avec une précision remarquable, facilitant ainsi le diagnostic de maladies comme le cancer. Par exemple, des systèmes d'IA peuvent détecter des anomalies dans les radiographies pulmonaires plus rapidement et avec une précision comparable à celle des radiologues expérimentés.



Figure 5 : Diagnostic médical Assisté par l'IA.

En outre, l'IA permet de développer des traitements personnalisés en analysant les données génétiques et les dossiers médicaux des patients. Des plateformes comme IBM Watson Health utilisent l'IA pour recommander des traitements adaptés aux caractéristiques spécifiques de chaque patient, améliorant ainsi les résultats thérapeutiques et réduisant les effets secondaires.

Gestion des Soins de Santé :



Figure 6: Assistance personnalisée.

L'IA est également utilisée pour optimiser la gestion des soins de santé. Les systèmes d'IA peuvent prévoir les admissions à l'hôpital, gérer les flux de patients et améliorer l'affectation des ressources. Par exemple, l'analyse prédictive peut aider à anticiper les pics de demande dans les services d'urgence, permettant une allocation plus efficace du personnel et des équipements.

Finance

Analyse et Prévision des Marchés :

Dans le secteur financier, l'IA est utilisée pour l'analyse des données de marché et la prévision des tendances économiques. Les algorithmes de trading automatisé exploitent des quantités massives de données pour identifier des opportunités d'investissement en temps réel, améliorant ainsi la réactivité et l'efficacité des transactions financières. Prévision du marché.

Détection des Fraudes

L'IA joue également un rôle crucial dans la détection des fraudes. Les systèmes de surveillance des transactions utilisent l'apprentissage automatique pour identifier des comportements suspects et des anomalies qui pourraient indiquer une activité frauduleuse. Par exemple, les banques utilisent des algorithmes d'IA pour surveiller les transactions en temps réel et bloquer automatiquement celles qui présentent un risque élevé de fraude.

Éducation

Personnalisation de l'Apprentissage :

L'IA transforme le secteur éducatif en permettant une personnalisation accrue de l'apprentissage. Les plateformes d'apprentissage adaptatif utilisent l'IA pour analyser les performances des étudiants et adapter les contenus pédagogiques à leurs besoins spécifiques. Cela permet de proposer des parcours d'apprentissage individualisés, renforçant l'engagement des étudiants et améliorant leurs résultats académiques.



Figure 7: Assistance de l'apprentissage en ligne.

Automatisation des Tâches Administratives :

Les technologies d'IA sont également utilisées pour automatiser les tâches administratives dans les établissements d'enseignement.



Figure 8: Chatbot.

Par exemple, des chatbots alimentés par l'IA peuvent répondre aux questions fréquentes des étudiants, libérant ainsi le personnel administratif pour se concentrer sur des tâches plus complexes.

Industrie

Automatisation des Processus de Production :

L'IA révolutionne le secteur industriel en automatisant les processus de production. Les robots intelligents, dotés de capacités d'apprentissage et de vision par ordinateur, peuvent exécuter des tâches complexes avec une précision et une efficacité accrue. Cela permet non seulement d'augmenter la productivité, mais aussi de réduire les erreurs et les coûts de production.



Figure 9:Industrie.

Transport

Véhicules Autonomes :

L'une des applications les plus médiatisées de l'IA dans le secteur des transports est celle des véhicules autonomes. Les voitures autonomes utilisent des algorithmes d'apprentissage profond et des systèmes de vision par ordinateur pour percevoir leur environnement, prendre des décisions de Conduite et naviguer en toute sécurité. Des entreprises comme Tesla et Waymo sont à la pointe de cette technologie, visant à révolutionner la mobilité urbaine et à améliorer la sécurité routière.



Figure 10: Voiture autonome.

Gestion du Trafic :

L'IA contribue également à la gestion du trafic urbain. Les systèmes de gestion intelligente du trafic utilisent l'IA pour analyser les flux de véhicules en temps réel et optimiser les feux de signalisation, réduisant ainsi les embouteillages et les émissions de gaz à effet de serre. Par exemple, certaines villes utilisent des caméras et des capteurs pour surveiller le trafic et ajuster dynamiquement les cycles des feux de signalisation en fonction des conditions actuelles.

Agriculture

Agriculture de Précision :

L'IA est en train de transformer l'agriculture grâce à des techniques d'agriculture de précision. Les drones et les capteurs équipés de technologies d'IA peuvent surveiller les cultures et le sol, fournissant des données détaillées sur l'état des cultures, les niveaux de nutriments et l'humidité du sol. Ces informations permettent aux agriculteurs de prendre des décisions éclairées sur l'irrigation, la fertilisation et la récolte, augmentant ainsi les rendements tout en réduisant l'utilisation des ressources.



Figure 11: Drone de l'agriculture.

Gestion des Parasites :

Les systèmes d'IA peuvent également aider à gérer les parasites en analysant les images des cultures pour détecter les signes précoces d'infestation. Cela permet une intervention rapide et ciblée, minimisant l'impact des parasites sur les rendements et réduisant la dépendance aux pesticides chimiques.

Conclusion

L'intelligence artificielle est une technologie aux applications vastes et variées, capable de transformer profondément de nombreux secteurs. De la médecine à la finance, en passant par l'éducation, l'industrie, les transports et l'agriculture, l'IA apporte des innovations significatives et des améliorations en termes d'efficacité, de précision et de personnalisation. Cependant, ces avancées s'accompagnent de défis, notamment en matière de sécurité, d'éthique et de gestion des transitions économiques et sociales. Il est donc essentiel de poursuivre les recherches et les débats sur les meilleures façons d'intégrer l'IA de manière bénéfique et équitable dans nos sociétés.

II.5 Défis et Opportunités pour l'Avenir de l'IA :

Introduction

L'intelligence artificielle (IA) est l'une des technologies les plus influentes du 21ème siècle, promettant de transformer des aspects variés de la vie humaine et de l'activité économique. Cependant, cette transformation s'accompagne de défis complexes qui doivent être surmontés pour réaliser pleinement les opportunités offertes par l'IA. Cet essai examine les principaux défis et opportunités pour l'avenir de l'IA, en mettant en lumière les enjeux éthiques, économiques et sociaux ainsi que les potentiels de croissance et d'innovation.

Défis de l'IA

Éthique et Biais :

L'un des défis majeurs de l'IA réside dans les questions éthiques et les biais inhérents aux algorithmes. Les systèmes d'IA apprennent à partir de données qui peuvent contenir des biais historiques ou culturels, entraînant des décisions injustes ou discriminatoires. Par exemple, les algorithmes de reconnaissance faciale ont montré des taux d'erreur plus élevés pour les personnes de couleur, reflétant les biais présents dans les données d'entraînement. Pour relever ce défi, il est crucial de développer des approches pour identifier et atténuer les biais dans les données et les algorithmes. Cela inclut la diversification des ensembles de données, la transparence des modèles d'IA et l'élaboration de normes éthiques rigoureuses pour guider le développement et l'utilisation de l'IA.

Sécurité et Confidentialité :

La sécurité et la confidentialité des données sont des préoccupations essentielles dans le déploiement de l'IA. Les systèmes d'IA traitent souvent des informations sensibles, ce qui les rend vulnérables aux cyberattaques et aux violations de données. Les incidents de piratage et de fuite de données peuvent entraîner des pertes financières importantes, des dommages à la réputation et des atteintes à la vie privée des individus. Pour garantir la sécurité des systèmes d'IA, il est nécessaire de mettre en place des protocoles de sécurité robustes, des méthodes de chiffrement avancées et des pratiques de gestion des données responsables. De plus, les réglementations doivent être renforcées pour protéger la confidentialité des utilisateurs et assurer une utilisation éthique des données.

Impact sur l'Emploi :

L'automatisation par l'IA pose des défis significatifs pour le marché du travail. Si l'IA peut augmenter la productivité et créer de nouveaux emplois dans les secteurs technologiques, elle peut également conduire à la suppression de postes dans des industries traditionnelles. Cette transition peut exacerber les inégalités économiques et créer des tensions sociales si elle n'est pas correctement gérée. Pour atténuer ces impacts, il est essentiel de mettre en œuvre des politiques de reconversion professionnelle et de formation continue pour aider les travailleurs à s'adapter aux nouvelles exigences du marché du travail. Les gouvernements et les entreprises doivent collaborer pour soutenir les initiatives d'éducation et de formation qui préparent la main-d'œuvre aux compétences du futur.

Opportunités de l'IA

Innovation et Croissance Économique :

L'IA offre des opportunités sans précédent pour l'innovation et la croissance économique. Les entreprises peuvent utiliser l'IA pour optimiser leurs opérations, améliorer leurs produits et services,

et explorer de nouveaux modèles d'affaires. Par exemple, l'IA peut améliorer l'efficacité des chaînes d'approvisionnement, permettre la personnalisation à grande échelle des produits et services, et stimuler l'innovation dans des domaines comme la santé, l'énergie et l'agriculture. Les gouvernements et les institutions doivent encourager l'investissement dans la recherche et le développement de l'IA, soutenir les startups technologiques et créer des écosystèmes favorables à l'innovation. Cela inclut également la mise en place de réglementations adaptées qui favorisent l'expérimentation tout en protégeant les droits des individus.

Amélioration de la Qualité de Vie :

L'IA a le potentiel d'améliorer considérablement la qualité de vie. Dans le domaine de la santé, l'IA peut aider à diagnostiquer des maladies plus rapidement et avec une plus grande précision, optimiser les traitements et personnaliser les soins pour chaque patient. Dans l'éducation, l'IA peut offrir des expériences d'apprentissage personnalisées, adaptées aux besoins spécifiques de chaque élève, et aider à combler les lacunes éducatives. De plus, l'IA peut contribuer à résoudre des problèmes sociaux complexes, comme le changement climatique, en optimisant l'utilisation des ressources et en développant des solutions durables. Par exemple, l'IA peut aider à gérer les réseaux électriques intelligents, améliorer l'efficacité énergétique des bâtiments et prédire les tendances météorologiques pour mieux planifier les interventions environnementales.

Transformation des Industries :

L'IA est en train de transformer de nombreuses industries, en augmentant l'efficacité, en réduisant les coûts et en ouvrant de nouvelles opportunités. Dans le secteur manufacturier, l'automatisation intelligente permet des processus de production plus flexibles et efficaces. Dans les transports, les véhicules autonomes promettent de révolutionner la mobilité et de réduire les accidents de la route. En finance, l'IA est utilisée pour détecter les fraudes, gérer les risques et améliorer les décisions d'investissement. Dans l'agriculture, les technologies d'IA permettent une agriculture de précision qui maximise les rendements tout en minimisant l'utilisation des ressources. Ces transformations nécessitent une adaptation des modèles d'affaires et des stratégies de gestion pour tirer parti des avantages de l'IA.

Conclusion :

L'avenir de l'IA est porteur de nombreuses opportunités et de défis significatifs. Pour tirer pleinement parti des avantages de cette technologie, il est essentiel de relever les défis éthiques, sécuritaires et sociaux qu'elle pose. En même temps, les opportunités offertes par l'IA en termes d'innovation, de croissance économique et d'amélioration de la qualité de vie sont immenses. Les gouvernements, les entreprises, les chercheurs et la société civile doivent collaborer pour développer des stratégies et des politiques qui maximisent les bénéfices de l'IA tout en minimisant ses risques. Cela inclut l'investissement dans la recherche et l'éducation, l'élaboration de réglementations éthiques, et la promotion d'une utilisation responsable et équitable de l'IA. En abordant ces défis et en saisissant ces opportunités, nous pouvons construire un avenir où l'IA contribue positivement au bien-être de l'humanité et à la prospérité économique.

Chapitre III :

Exploration des méthodes de détection de la pneumonie

III.1 Introduction :

La pneumonie, une infection pulmonaire pouvant être causée par des bactéries, des virus ou des champignons, reste une menace importante pour la santé publique mondiale. Elle est responsable de millions de décès chaque année, notamment parmi les jeunes enfants et les personnes âgées. La détection précoce et précise de la pneumonie est cruciale pour un traitement efficace et pour réduire la mortalité associée à cette maladie. Cet essai explore l'état de l'art des méthodes de détection de la pneumonie, en mettant l'accent sur les techniques traditionnelles et les innovations récentes, notamment celles basées sur l'intelligence artificielle (IA).

III.2 Etat de l'art de la détection de la pneumonie :

Parmi les méthodes de détection de la pneumonie il existe :

- Méthodes traditionnelles de détection de la pneumonie
- Innovations Récentes dans la détection de la pneumonie

III.2.1 Méthodes traditionnelles de détection de la pneumonie :

Il existe plusieurs méthodes traditionnelles parmi lesquelles on cite :

Radiographie Thoracique :

La radiographie thoracique est l'une des méthodes les plus couramment utilisées pour diagnostiquer la pneumonie. Les médecins examinent les images radiographiques pour identifier les signes de pneumonie, tels que les opacités pulmonaires, qui indiquent la présence de liquide ou d'inflammation dans les poumons. Cette méthode, bien que largement accessible, dépend fortement de l'expertise du radiologue et peut être sujette à des erreurs d'interprétation.

Auscultation et examen physique :

L'auscultation, qui consiste à écouter les sons pulmonaires à l'aide d'un stéthoscope, est une autre technique traditionnelle de détection de la pneumonie. Les médecins cherchent des bruits anormaux tels que des crépitements ou des râles, qui peuvent indiquer une infection pulmonaire. Bien que l'auscultation soit une méthode rapide et non invasive, elle manque souvent de spécificité et de sensibilité, nécessitant souvent des examens complémentaires pour confirmer le diagnostic.



Figure 12: image du thorax.

Tests du laboratoire :

Les tests de laboratoire, incluant les analyses de sang et les cultures de sécrétions pulmonaires, sont utilisés pour identifier les agents pathogènes responsables de la pneumonie. Ces tests peuvent déterminer si l'infection est d'origine bactérienne, virale ou fongique, ce qui est essentiel pour orienter le traitement. Cependant, les tests de laboratoire peuvent être coûteux, nécessiter du temps et ne sont pas toujours disponibles dans les régions à ressources limitées.

Note :

Les méthodes traditionnelles de détection de la pneumonie, telles que la radiographie thoracique, l'auscultation et les tests de laboratoire, présentent des limitations significatives. Ces méthodes dépendent fortement de l'expertise humaine, sont sujettes à des erreurs d'interprétation et peuvent manquer de spécificité et de sensibilité. De plus, elles peuvent être coûteuses, avoir des délais de réponse prolongés et, dans le cas de la radiographie, exposer les patients à des radiations. Ces limitations soulignent la nécessité d'améliorer les techniques existantes et d'intégrer des innovations technologiques pour optimiser le diagnostic et le traitement de la pneumonie.

III.2.2 Innovations récentes de détection de la pneumonie :

Parmi les innovations récentes on cite :

Algorithmes de deep learning pour l'analyse des images

L'une des applications les plus prometteuses de l'IA dans la détection de la pneumonie est l'utilisation d'algorithmes de deep learning pour l'analyse d'images radiographiques. Les réseaux de neurones convolutifs (CNN), en particulier, ont montré une grande efficacité dans l'identification des caractéristiques associées à la pneumonie sur les radiographies thoraciques. Des études ont démontré que les modèles de deep learning peuvent atteindre une précision comparable, voire supérieure, à celle des radiologues humains. Par exemple, un modèle développé par Google Health a montré une performance élevée dans la détection de la pneumonie sur les radiographies thoraciques,

avec une sensibilité et une spécificité améliorée par rapport aux méthodes traditionnelles. Ces algorithmes peuvent également être intégrés dans des systèmes d'aide à la décision clinique, offrant ainsi un outil précieux pour les médecins dans des environnements à ressources limitées.

Applications mobiles et télémédecines :

Avec l'essor des technologies mobiles et de la télémédecine, des applications basées sur l'IA sont développées pour faciliter le diagnostic de la pneumonie à distance. Ces applications permettent aux utilisateurs de télécharger des images radiographiques et d'obtenir des analyses automatisées en temps réel. Cela est particulièrement utile dans les zones rurales et les pays en développement, où l'accès aux spécialistes est limité. Un exemple notable est l'application COVID-Net, qui a été initialement développée pour détecter les infections à COVID-19 sur les radiographies thoraciques, mais qui a également montré son efficacité pour la détection de la pneumonie. De telles applications peuvent accélérer le diagnostic et permettre une intervention médicale rapide, améliorant ainsi les résultats cliniques.

Modèles prédictifs et Analyse de données massives (Big Data) :

L'analyse de données massives (big data) et les modèles prédictifs basés sur l'IA sont également utilisés pour anticiper les épidémies de pneumonie et optimiser les ressources de santé publique. En analysant de vastes ensembles de données cliniques et épidémiologiques, ces modèles peuvent identifier des tendances et des facteurs de risque associés à la pneumonie, permettant une réponse proactive. Par exemple, des chercheurs ont utilisé des techniques d'apprentissage automatique pour prédire les flambées de pneumonie en fonction des données météorologiques, des habitudes de voyage et des indicateurs de santé publique. Ces informations peuvent aider les autorités sanitaires à préparer des interventions ciblées, comme la distribution de vaccins ou le renforcement des capacités hospitalières, pour prévenir et contrôler les épidémies.

Chapitre IV :

Apprentissage automatique (Machine learning)

IV.1 Concepts de base de machine learning :

Le machine learning, ou apprentissage automatique, est une branche de l'intelligence artificielle qui se concentre sur le développement d'algorithmes et de techniques permettant aux ordinateurs de "apprendre" à partir de données. En d'autres termes, il s'agit de permettre aux machines d'améliorer leurs performances sur une tâche donnée sans être explicitement programmées pour chaque étape. Ce domaine est crucial dans de nombreuses applications modernes, telles que la reconnaissance vocale, la vision par ordinateur, les systèmes de recommandation, et bien plus encore. Ce texte explore les concepts fondamentaux du machine learning, en détaillant les types d'apprentissage, les algorithmes principaux, et les défis associés.

Autre définition :

<< " L'apprentissage automatique est le domaine d'étude qui donne aux ordinateurs la capacité d'apprendre sans être explicitement programmés." >>

IV.1.1 Algorithmes de Machine Learning :

Plusieurs algorithmes sont couramment utilisés en machine learning, chacun ayant ses propres avantages et inconvénients. Voici une description de quelques-uns des algorithmes les plus populaires.

Régression linéaire :

La régression linéaire est l'un des modèles les plus simples et les plus fondamentaux en machine learning supervisé. Elle tente de modéliser la relation entre une variable dépendante et une ou plusieurs variables indépendantes en ajustant une ligne (ou un hyperplan dans des dimensions supérieures) qui minimise l'erreur quadratique moyenne.

Machines à vecteurs de support :

Les SVM sont utilisés à la fois pour la classification et la régression. Cet algorithme cherche à trouver l'hyperplan optimal qui sépare les classes dans un espace de haute dimension, maximisant ainsi la marge entre les différentes classes. Pour les cas non linéaires, les SVM utilisent des noyaux pour transformer les données d'entrée.

Arbres de décision et forêt aléatoire :

Les arbres de décision sont des modèles prédictifs qui utilisent une structure arborescente pour prendre des décisions basées sur les valeurs des caractéristiques d'entrée. Les forêts aléatoires sont une extension des arbres de décision, où plusieurs arbres sont entraînés sur différentes parties des données et leurs prédictions sont moyennées pour améliorer la précision et réduire le surapprentissage.

Réseaux de neurones et apprentissage profond :

Les réseaux de neurones artificiels, inspirés du fonctionnement du cerveau humain, sont composés de couches de nœuds (neurones) interconnectés. Les réseaux de neurones profonds, ou deep learning, utilisent plusieurs couches cachées, ce qui leur permet de modéliser des relations complexes dans les données. Les architectures courantes incluent les réseaux de neurones convolutionnels (CNN) pour la vision par ordinateur et les réseaux de neurones récurrents (RNN) pour les données séquentielles.

IV.1.2 Enjeux et défis du machine learning :

Bien que le machine learning ait connu un succès considérable, plusieurs défis doivent encore être relevés pour améliorer ses performances et son applicabilité.

Sur-apprentissage et sous-apprentissage :

Le surapprentissage (overfitting) se produit lorsque le modèle apprend trop bien les détails et le bruit des données d'entraînement, au détriment de sa capacité à généraliser sur des données non vues. Le sous-apprentissage (underfitting) survient lorsque le modèle est trop simple pour capturer les tendances sous-jacentes des données. Trouver le bon équilibre entre complexité du modèle et généralisation est crucial.

Biais et variance :

Le biais et la variance sont deux sources d'erreur dans les modèles de machine learning. Un biais élevé indique que le modèle est trop simplifié et ne capture pas les tendances des données (erreur systématique), tandis qu'une variance élevée signifie que le modèle est trop complexe et sensible aux fluctuations des données d'entraînement (erreur due à la complexité). Le compromis biais-variance est un aspect clé de la construction des modèles.

Données et prétraitement :

La qualité et la quantité des données sont des facteurs déterminants dans la performance des modèles de machine learning. Les données manquantes, les valeurs aberrantes et les biais dans les données peuvent gravement affecter les résultats. Un prétraitement rigoureux des données, y compris la normalisation, la standardisation et la sélection de caractéristiques, est essentiel.

En fin, Le machine learning représente une révolution technologique avec des applications vastes et variées. Les concepts de base, tels que les types d'apprentissage, les algorithmes principaux, et les défis associés, constituent les fondements sur lesquels repose cette discipline. À mesure que les technologies évoluent, il est crucial de continuer à explorer et à comprendre ces concepts pour développer des systèmes plus performants, équitables et explicables. L'avenir du machine learning dépendra de notre capacité à surmonter les défis actuels et à intégrer de manière responsable ces technologies dans nos sociétés.

IV.2 Types d'apprentissage (Supervisé – non Supervisé – Sémi Supervisé) :

Le machine learning se divise généralement en trois catégories principales : l'apprentissage supervisé, l'apprentissage non supervisé et l'apprentissage par renforcement. Chacune de ces catégories correspond à un type particulier de problème et utilise des techniques spécifiques.

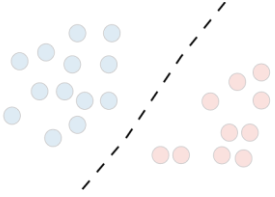
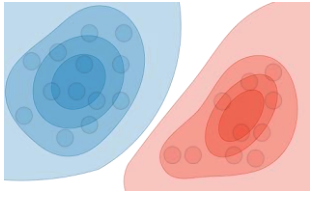
IV.2.1 Apprentissage Supervisé :

Etant donné un ensemble de points $\{x^{(1)}, \dots, x^{(m)}\}$ associé à un ensemble d'issues $\{y^{(1)}, \dots, y^{(m)}\}$, on peut construire un classifieur qui apprend à prédire y depuis x .

□ **Type de prédiction** – Les différents types de modèle prédictifs sont résumés dans le tableau ci-dessous :

	Régression	Classifieur
Issue	Continu	Classe
Exemples	Régression linéaire	Régression logistique, SVM, Naive Bayes

□ **Type de modèle** – Les différents modèles les plus connus sont présentés dans le tableau ci-dessous :

	Modèle discriminatif	Modèle génératif
But	Estimer directement $P(y/x)$	Estimer $P(x/y)$ puis déduire $P(y/x)$
Ce qui est appris	Frontière de décision	Distribution de proba des données
Illustration		
Exemples	Régressions, SVMs	GDA, Naive Bayes

Notations et concepts généraux :

□ **hypothèse** : Une hypothèse est notée h_{ϑ} et est le modèle que l'on choisit. Pour une entrée donnée $x^{(i)}$, la prédiction donnée par le modèle est $h_{\vartheta}(x^{(i)})$.


□ **Fonction de loss** – Une fonction de loss est une fonction $L : (z, y) \in \mathbb{R} \times Y \rightarrow \mathbb{R}$ prenant comme entrée une valeur prédite z correspondant à une valeur réelle y , et nous renseigne sur la ressemblance de ces deux valeurs.

□ **Fonction de coût** : La fonction de coût J est communément utilisée pour évaluer la performance d'un modèle, et est définie avec la fonction de loss L par :

$$J(\theta_0, \theta_1) = \frac{1}{2M} \sum_{i=1}^M (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

□ **Algorithme du gradient** : En notant $\alpha \in \mathbb{R}$ le taux d'apprentissage (en anglais Learning rate), la règle de mise à jour de l'algorithme est exprimée en fonction du taux d'apprentissage et de la fonction de cost J de la manière suivante :

$$\vartheta \leftarrow \vartheta - \alpha \nabla J(\vartheta)$$



Remarque : L'algorithme du gradient stochastique (en anglais SGD - Stochastic Gradient Descent) met à jour le paramètre à partir de chaque élément du jeu d'entraînement, tandis que l'algorithme du gradient de batch le fait sur chaque lot d'exemples.

IV.2.2 Apprentissage Non Supervisé :

□ Motivation :

Le but de l'apprentissage non-supervisé est de trouver des formes cachées dans un jeu de données non-labelées $\{x(1), \dots, x(m)\}$.

L'apprentissage non supervisé est une branche fondamentale du machine learning, où le modèle est formé sur des données sans étiquettes. Contrairement à l'apprentissage supervisé, il n'y a pas de sortie cible à laquelle le modèle doit correspondre. L'objectif principal de l'apprentissage non supervisé est de découvrir des structures cachées, des motifs ou des regroupements dans les données. Ce texte présente une vue d'ensemble des concepts clés, des algorithmes principaux et des équations associées à l'apprentissage non supervisé.

Concepts de Base:

Clustering

Le clustering est une méthode de partitionnement des données en groupes ou clusters, où les objets dans le même cluster sont plus similaires entre eux qu'à ceux des autres clusters. Les algorithmes de clustering les plus courants incluent k-means, DBSCAN et agglomératif.

Réduction de Dimensionnalité

La réduction de dimensionnalité vise à diminuer le nombre de variables sous-jacentes dans les données tout en préservant autant d'information que possible. Les techniques courantes incluent l'Analyse en Composantes Principales (PCA) et l'Analyse Discriminante Linéaire (LDA).

Apprentissage par Renforcement

Bien que souvent classé différemment, certaines techniques d'apprentissage par renforcement sont non supervisées, où l'agent apprend par essais et erreurs sans guide explicite.

Comparaison avec l'Apprentissage Supervisé :

Dans l'apprentissage supervisé, chaque exemple d'entraînement est accompagné d'une étiquette ou d'un résultat souhaité. L'algorithme apprend à mapper les entrées aux sorties en minimisant une fonction de perte. En revanche, l'apprentissage non supervisé n'a pas de telles étiquettes et se concentre sur la modélisation de la structure des données pour en extraire des informations utiles. Cela le rend particulièrement adapté à des situations où l'étiquetage des données est coûteux ou impraticable.

Applications Pratiques :

Segmentation de Clients :

Dans le domaine du marketing, l'apprentissage non supervisé est utilisé pour la segmentation de clients, où les entreprises regroupent leurs clients en segments distincts pour personnaliser leurs stratégies de marketing. Par exemple, l'analyse des comportements d'achat peut révéler des groupes de clients ayant des préférences similaires, permettant ainsi des campagnes marketing plus ciblées et efficaces.

Détection d'Anomalies :

La détection d'anomalies est cruciale dans de nombreux domaines, y compris la cybersécurité, la finance, et la maintenance prédictive. Les algorithmes d'apprentissage non supervisé, tels que le clustering et l'estimation de densité, sont utilisés pour identifier des comportements ou des motifs inhabituels dans les données. Par exemple, dans la détection de fraude financière, l'apprentissage non supervisé peut aider à identifier des transactions suspectes sans nécessiter de données étiquetées.

Bioinformatique :

Dans la bioinformatique, l'apprentissage non supervisé est appliqué à l'analyse de données génomiques et protéomiques pour découvrir des structures biologiques sous-jacentes. Par exemple, le clustering est utilisé pour identifier des sous-types de cancer à partir de données d'expression génique, aidant ainsi à la personnalisation des traitements médicaux.

Conclusion :

L'apprentissage non supervisé joue un rôle crucial dans l'exploration et l'analyse des données sans étiquettes. Ses applications vont de la segmentation de clients à la détection d'anomalies, en passant par la bioinformatique. Malgré les défis liés à l'évaluation et à l'interprétation des modèles, les

progrès continus dans ce domaine promettent d'ouvrir de nouvelles possibilités pour comprendre et exploiter les données de manière plus efficace et approfondie. En tant que domaine de recherche en pleine expansion, l'apprentissage non supervisé continuera d'être au cœur des innovations dans l'apprentissage automatique et l'intelligence artificielle.

IV.3 Applications du Machine Learning dans différents domaines :

Introduction :

Le machine learning (ML), une sous-discipline de l'intelligence artificielle (IA), a transformé divers secteurs par sa capacité à apprendre à partir des données et à faire des prédictions ou des décisions sans être explicitement programmée pour chaque tâche spécifique. Cette technologie repose sur des algorithmes qui identifient des modèles dans des ensembles de données, permettant ainsi des applications variées et efficaces. Cet article explore les applications pratiques du machine learning dans plusieurs domaines : la santé, les finances, le marketing, la production industrielle, et les transports.

Santé:

L'une des applications les plus prometteuses du machine learning se trouve dans le diagnostic médical. Des algorithmes sophistiqués, tels que les réseaux de neurones convolutifs (CNN), sont utilisés pour analyser les images médicales. Par exemple, les systèmes de ML peuvent détecter des anomalies dans les radiographies pulmonaires pour diagnostiquer la pneumonie ou identifier des tumeurs cancéreuses dans des images de mammographies avec une précision comparable, voire supérieure, à celle des radiologues humains.

Finances :

Dans le secteur financier, le machine learning est largement utilisé pour la détection de fraude. Les algorithmes d'apprentissage supervisé et non supervisé, tels que les forêts d'arbres décisionnels et les machines à vecteurs de support (SVM), analysent les transactions pour identifier des comportements suspects ou anormaux. Ces systèmes sont capables de détecter des motifs de fraude en temps réel, réduisant ainsi les pertes financières et augmentant la sécurité des transactions.

Marketing :

Le machine learning révolutionne le marketing, notamment à travers l'analyse de sentiment. Les algorithmes de traitement du langage naturel (NLP), tels que les modèles de transformer comme BERT, analysent les avis des consommateurs sur les réseaux sociaux et autres plateformes pour déterminer les opinions et sentiments envers des produits ou des marques. Cette analyse aide les entreprises à ajuster leurs stratégies marketing en temps réel pour mieux répondre aux attentes des clients.

Conclusion :

En conclusion, le machine learning joue un rôle crucial dans de nombreux domaines, transformant la manière dont les entreprises et les institutions fonctionnent. Dans le secteur de la santé, il améliore le diagnostic et la médecine personnalisée. Dans les finances, il renforce la détection de fraude et le trading algorithmique. Dans le marketing, il permet une analyse de sentiment et une personnalisation accrue. Dans l'industrie, il optimise les processus de production et la maintenance prédictive. Enfin, dans les transports, il révolutionne les véhicules autonomes et la gestion du trafic. Ces applications pratiques démontrent le potentiel énorme du machine learning à améliorer l'efficacité, la précision et la qualité dans divers domaines, annonçant une ère de plus en plus automatisée et intelligente.


Chapitre V :

Apprentissage Profond (Deep Learning)

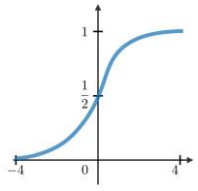
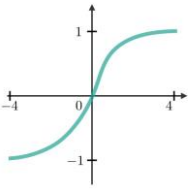
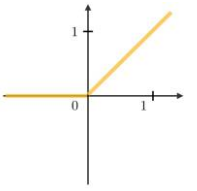
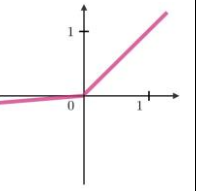
V.1 Introduction aux réseaux de neurones :

Les réseaux de neurones (en anglais neural networks) sont une classe de modèles qui sont construits à l'aide de couches de neurones. Les réseaux de neurones convolutionnels (en anglais **convolutional neural networks**) ainsi que les réseaux de neurones récurrents (en anglais **recurrent neural networks**) font partie des principaux types de réseaux de neurones.

□ **Architecture** : Le vocabulaire autour des architectures des réseaux de neurones est décrit dans la figure ci-dessous :



□ **Fonction d'activation** : Les fonctions d'activation sont utilisées à la fin d'une unité de couche cachée pour introduire des complexités non linéaires au modèle. En voici les plus fréquentes :

Sigmoïde	Tanh	ReLU	Leaky ReLU
$g(z) = \frac{1}{1 + e^{-z}}$	$g(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$	$g(z) = \max(0, z)$	$g(z) = \max(z, z \text{ with } 1)$
			

□ **Taux d'apprentissage** : Le taux d'apprentissage (appelé en anglais learning rate), souvent noté α ou parfois η , indique la vitesse à laquelle les coefficients évoluent. Cette quantité peut être fixe ou

variable. L'une des méthodes les plus populaires à l'heure actuelle s'appelle Adam, qui a un taux d'apprentissage qui s'adapte au fil du temps.

❑ **Rétropropagation du gradient** : La rétropropagation du gradient (en anglais back propagation) est une méthode destinée à mettre à jour les coefficients d'un réseau de neurones en comparant la sortie obtenue et la sortie désirée. La dérivée par rapport au coefficient w est calculée à l'aide du théorème de dérivation des fonctions composées.

Les réseaux de neurones artificiels (RNA) sont une classe de modèles d'apprentissage automatique inspirés par le fonctionnement du cerveau humain. Ils sont composés de multiples couches de neurones artificiels interconnectés, chacun capable d'effectuer des calculs complexes et d'apprendre des représentations à partir de données d'entrée. L'architecture des RNA joue un rôle crucial dans leur performance et leur capacité à généraliser les informations apprises. Cet article explore les différents aspects de l'architecture des réseaux de neurones, y compris les types de couches, les structures récurrentes, et les techniques d'optimisation.

Types de Couches dans les Réseaux de Neurones

Couches Denses (Fully Connected Layers) :

Les couches denses, ou couches entièrement connectées, sont les plus simples et les plus courantes dans les architectures de RNA. Chaque neurone dans une couche dense est connecté à tous les neurones de la couche précédente. La sortie d'une couche dense est calculée par une combinaison linéaire des entrées, suivie d'une fonction d'activation non-linéaire. Mathématiquement, cela peut être représenté comme suit :

$$Y = f(Wx + b)$$

où y est le vecteur de sortie, W est la matrice de poids, x est le vecteur d'entrée, b est le vecteur de biais, et f est la fonction d'activation.

Couches Convolutives (Convolutional Layers) :

Les couches convolutives sont principalement utilisées dans les réseaux de neurones convolutionnels (CNN) pour les tâches de traitement d'images. Elles exploitent des filtres ou des noyaux qui glissent sur l'entrée pour détecter des motifs locaux. Cette opération est formellement définie par une convolution discrète. Les filtres partagent les poids, réduisant ainsi le nombre de paramètres et permettant une meilleure généralisation.

Structures Avancées des Réseaux de Neurones

Réseaux de Neurones Profonds (Deep Neural Networks) :

Les réseaux de neurones profonds (DNN) sont caractérisés par un grand nombre de couches cachées. Cette profondeur permet au réseau d'apprendre des représentations hiérarchiques des données,

chaque couche capturant des niveaux de complexité croissants. Cependant, l'entraînement des DNN peut être difficile en raison de problèmes comme la disparition du gradient.

Techniques d'Optimisation

Algorithmes de Descente de Gradient :

L'entraînement des réseaux de neurones implique l'optimisation d'une fonction de perte par descente de gradient. Les variantes comme la descente de gradient stochastique (SGD), Adam, RMSprop, et AdaGrad sont couramment utilisées pour améliorer la convergence et la performance. Ces algorithmes ajustent les poids du réseau pour minimiser l'erreur entre les prédictions et les vraies valeurs.

Régularisation :

La régularisation est essentielle pour prévenir le surapprentissage (overfitting). Les techniques comme la régularisation L2 (ridge regression), le dropout, et la normalisation des lots (batch normalization) sont couramment appliquées. Le dropout, par exemple, consiste à ignorer aléatoirement des neurones pendant l'entraînement, ce qui force le réseau à apprendre des représentations redondantes et robustes.

Remarque : L'architecture des réseaux de neurones artificiels est un domaine riche et en constante évolution. La conception efficace des réseaux, incluant le choix des types de couches, la profondeur du réseau, et les techniques d'optimisation, est cruciale pour atteindre des performances optimales. Les avancées récentes, telles que les réseaux résiduels et les techniques de régularisation avancées, continuent de pousser les limites de ce que les RNA peuvent accomplir, ouvrant la voie à des applications toujours plus innovantes et efficaces.

V.2 Avancées récentes et Applications du Deep Learning :

Le deep learning, ou apprentissage profond, constitue une sous-catégorie de l'apprentissage automatique inspirée par la structure et le fonctionnement du cerveau humain, en particulier les réseaux neuronaux artificiels. Ces dernières années, les avancées dans ce domaine ont révolutionné de nombreux secteurs, notamment la vision par ordinateur, le traitement du langage naturel et les systèmes de recommandation. Cet essor a été rendu possible grâce à l'augmentation des capacités de calcul, l'accès à de vastes ensembles de données et des innovations algorithmiques majeures.

Architecture des réseaux neuronaux :

L'évolution des architectures de réseaux neuronaux a été l'une des pierres angulaires des progrès du deep learning. Les réseaux convolutionnels (CNN) ont transformé la vision par ordinateur, tandis que les réseaux de neurones récurrents (RNN) et leurs variantes, comme les LSTM et GRU, ont permis des avancées significatives dans le traitement des séquences temporelles. Plus récemment, les Transformers ont supplanté les RNN dans de nombreuses tâches de traitement du langage naturel grâce à leur capacité à gérer efficacement des dépendances à long terme et à paralléliser les calculs.

Techniques d'Optimisation:

Les techniques d'optimisation jouent un rôle crucial dans la formation des réseaux de deep learning. Des optimisateurs tels que Adam, RMSprop, et les améliorations de la descente de gradient stochastique ont permis une convergence plus rapide et plus stable des modèles complexes. De plus, les stratégies d'entraînement comme le drop-out, la normalisation par batch (batch normalization) et la régularisation L2 ont été introduites pour prévenir le surajustement et améliorer la généralisation des modèles.

Applications du deep learning

Vision par Ordinateur :

En vision par ordinateur, le deep learning a permis des avancées majeures dans la reconnaissance d'objets, la segmentation d'images, la détection de visages et la vision industrielle. Par exemple, les CNN ont révolutionné la reconnaissance d'images, comme en témoignent les performances sur des benchmarks tels que [ImageNet](#). Des systèmes de diagnostic médical utilisent désormais des réseaux neuronaux pour identifier des anomalies dans des images de radiologie ou d'IRM avec une précision comparable à celle des experts humains.

Traitement du Langage Naturel :

Le traitement du langage naturel a bénéficié de modèles pré-entraînés comme BERT et GPT, qui ont établi de nouveaux standards pour des tâches telles que la traduction automatique, l'analyse de sentiments et la génération de texte. Les chatbots et assistants virtuels, intégrant ces technologies, offrent des interactions de plus en plus naturelles et personnalisées avec les utilisateurs.

Automatisation Industrielle :

Dans le secteur industriel, le deep learning est utilisé pour l'automatisation des processus de fabrication, la maintenance prédictive et le contrôle de qualité. Les modèles de deep learning analysent les données des capteurs en temps réel pour détecter des anomalies et anticiper les pannes, optimisant ainsi l'efficacité opérationnelle et réduisant les coûts.

Chapitre VI :

Vision par Ordinateur

(Computer vision)

VI.1 Principes de base de la vision par ordinateur :

Introduction :

La vision par ordinateur (VPO) est une sous-discipline de l'intelligence artificielle (IA) qui vise à permettre aux machines de comprendre et d'interpréter le contenu visuel du monde de manière similaire à l'humain. Les applications de la vision par ordinateur sont vastes, englobant des domaines tels que la reconnaissance d'images et de visages, la détection d'objets, l'analyse de vidéos, et la conduite autonome. Ce document explore les principes fondamentaux qui sous-tendent la vision par ordinateur, en mettant en évidence les concepts et les techniques essentiels.

Acquisition et Prétraitement des Images :

Le processus de vision par ordinateur commence par l'acquisition d'images à partir de capteurs, tels que des caméras. Les images capturées sont souvent bruitées ou mal calibrées, nécessitant un prétraitement pour améliorer la qualité des données. Les techniques de prétraitement courantes incluent :

- **Filtrage spatial** : Pour réduire le bruit et lisser les images.
- **Égalisation d'histogramme** : pour améliorer le contraste.
- **Transformation géométrique** : Pour corriger les distorsions et aligner les images.

Extraction des Caractéristiques

L'extraction des caractéristiques est cruciale pour la réduction de la dimensionnalité et pour représenter les images de manière plus concise et informative. Les caractéristiques peuvent être de bas niveau, telles que les bords, les coins, et les textures, ou de haut niveau, comme les descripteurs de formes et les points d'intérêt. Parmi les méthodes d'extraction des caractéristiques, on trouve :

- **Détection des bords (Sobel, Canny)** : Pour identifier les contours des objets.
- **Points d'intérêt (SIFT, SURF)** : Pour extraire des points caractéristiques robustes aux transformations.
- **Descripteurs de texture (LBP, GLCM)** : Pour quantifier les motifs de texture dans les images.

VI.2 Traitement des images médicales :

Le traitement des images médicales radiographiques constitue une branche essentielle de l'imagerie médicale, visant à améliorer la visualisation, l'interprétation et l'analyse des structures internes du corps humain. Ce domaine a évolué grâce aux avancées technologiques en informatique, mathématiques et radiologie, permettant des diagnostics plus précis et des traitements plus efficaces.

Méthodologies de Traitement des Images Radiographiques :

Le traitement des images radiographiques se divise en plusieurs étapes critiques, chacune jouant un rôle déterminant dans l'obtention d'images de haute qualité pour une interprétation clinique précise.

- **Acquisition et Prétraitement** : L'acquisition des images radiographiques est la première étape cruciale. Les rayons X traversent le corps et sont captés par un détecteur qui produit une image numérique. Cette image brute est ensuite soumise à un prétraitement pour corriger les artefacts inhérents aux techniques d'imagerie et améliorer le contraste.




Figure 13 : Images du Dataset.

- **Filtrage et Réduction du Bruit** : Les images radiographiques sont souvent bruitées en raison de diverses sources, telles que les mouvements du patient ou les limitations du détecteur. Des techniques de filtrage sophistiquées, comme les filtres passe-bas, la transformée de Fourier, et les algorithmes de débruitage avancés, sont appliquées pour atténuer ce bruit tout en préservant les détails essentiels des structures anatomiques.
- **Amélioration du Contraste** : Pour faciliter l'interprétation médicale, il est crucial d'améliorer le contraste des images radiographiques. Des méthodes telles que l'égalisation d'histogramme, le contraste adaptatif et l'amélioration par ondelettes sont couramment employées. Ces techniques accentuent les différences de densité entre les tissus, permettant une visualisation plus claire des anomalies pathologiques.

Algorithmes et Techniques Avancées

- **Apprentissage Profond et Réseaux de Neurones Convolutifs (CNN) :**

Les réseaux de neurones convolutifs (CNN) ont révolutionné l'analyse des images radiographiques. En entraînant des modèles sur des bases de données volumineuses, les CNN peuvent apprendre à identifier des motifs complexes et des anomalies avec une précision remarquable. Ils sont utilisés pour des tâches variées, allant de la détection des fractures à l'identification des nodules pulmonaires.

VI.3 Techniques de Pré-Traitement et de Post-Traitement des Données :

Le traitement des données joue un rôle crucial dans de nombreux domaines, notamment dans l'analyse des données, l'apprentissage automatique et les statistiques. Les techniques de pré-traitement et de post-traitement sont essentielles pour garantir la qualité des données et la pertinence des résultats obtenus. Cet article explore diverses méthodes de pré-traitement et de post-traitement des données, en soulignant leur importance et leurs applications pratiques.

Pré-Traitement des Données :

Le pré-traitement des données est l'étape initiale dans le flux de travail de l'analyse des données. Il vise à transformer les données brutes en un format approprié pour l'analyse. Cette étape est cruciale car des données mal préparées peuvent mener à des modèles peu performants et à des conclusions erronées.

Techniques de Pré-Traitement

1. Nettoyage des Données :

- **Gestion des Valeurs Manquantes** : Les valeurs manquantes peuvent être imputées à l'aide de diverses méthodes comme la moyenne, la médiane ou des techniques plus sophistiquées comme l'imputation par les k plus proches voisins (k-NN).
- **Correction des Valeurs Aberrantes** : Les valeurs extrêmes peuvent être détectées et traitées à l'aide de méthodes statistiques ou de boîtes à moustaches.

2. Normalisation et Standardisation :

- **Normalisation** : Mise à l'échelle des données pour qu'elles se situent dans un intervalle défini, généralement entre 0 et 1.
- **Standardisation** : Transformation des données pour qu'elles aient une moyenne de zéro et un écart-type de un, souvent utilisée dans les algorithmes de machine learning.

3. Réduction de Dimensionnalité :

- **Analyse en Composantes Principales (ACP)** : Méthode statistique utilisée pour réduire le nombre de variables tout en conservant la variance la plus élevée des données.
- **Sélection de Caractéristiques** : Utilisation d'algorithmes pour sélectionner les caractéristiques les plus pertinentes pour le modèle.

Post-Traitement des Données :

Le post-traitement des données intervient après l'étape d'analyse ou de modélisation. Il vise à interpréter, valider et améliorer les résultats obtenus. Cette étape est essentielle pour assurer la robustesse et la fiabilité des conclusions tirées.

Techniques de Post-Traitement

1. Évaluation des Modèles :

- **Validation Croisée** : Technique utilisée pour évaluer la performance des modèles sur des échantillons de données indépendants.
- **Métriques de Performance** : Utilisation de métriques comme la précision, le rappel, la F-mesure, et l'aire sous la courbe ROC pour évaluer la qualité des modèles.

2. Interprétation des Modèles :

- **Importance des Caractéristiques** : Analyse de l'importance des différentes caractéristiques utilisées dans le modèle.
- **Techniques de Visualisation** : Utilisation de graphiques et de visualisations pour interpréter et présenter les résultats de manière compréhensible.

3. Optimisation des Modèles :

- **Ajustement des Hyperparamètres** : Optimisation des hyperparamètres des modèles pour améliorer leur performance.
- **Ensemble learning** : Combinaison de plusieurs modèles pour obtenir de meilleures performances (ex : Bagging, Boosting).

En fin, Les techniques de pré-traitement et de post-traitement des données sont fondamentales pour garantir la qualité et la pertinence des analyses. Une bonne préparation des données améliore la performance des modèles, tandis qu'un post-traitement adéquat assure la validité et la fiabilité des résultats. La maîtrise de ces techniques est indispensable pour les professionnels de la data science et de l'analyse des données.

Chapitre VII :

Etude de cas :

(Détection de la pneumonie A l'aide de l'apprentissage profond.) (Deep Learning)

VII.1 Collecte et pré-traitement des données :

L'ensemble de données proposée utilisée pour évaluer les performances du modèle contient un total de 5 856 photos radiographiques du Kaggle. Le lien de l'ensemble de données est le suivant :

<https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia>

La base de données est organisée en trois dossiers (Train, Test, Val) et contient des sous-dossiers pour chaque catégorie d'image (PNEUMONIA/NORMAL).

Quelques exemples d'images courantes et de pneumonie sont répertoriés dans la figure 1. Les images radiographiques thoraciques présentent toujours des signes de luminosité limitée en raison de la faible dose d'exposition chez les patients, en raison de la radiographie thoracique. Images de rayons contenant toujours des pantalons noirs, blancs et gris Les poumons sont situés des deux côtés de la cavité thoracique et la zone pulmonaire peut être facilement détectée par les rayons X, qui sont presque noirs. Le cœur, situé entre les poumons, apparaît presque aussi blanc que les rayons X peuvent le traverser complètement. Les os sont constitués de protéines et très denses, de sorte que les rayons X ne peuvent pas les traverser et les os sont presque blancs. Ku de plus, les os ont des bords nets.



Figure 14: Exemples du dataset. (a) cas normaux.



Figure 15: Exemples du dataset. (b) cas anormaux.

Le pré-traitement des données :

Les stratégies utilisées tout au long de cet article sont répertoriées dans le tableau B. Dans notre étude, le rescale est une valeur par laquelle nous multiplierons les données avant tout autre traitement. Nos images originales sont constituées de coefficients RVB compris entre 0 et 255, mais ces valeurs seraient trop élevées pour que nos modèles puissent les traiter (étant donné un taux d'apprentissage typique). Nous ciblons donc des valeurs comprises entre 0 et 1 au lieu d'une mise à l'échelle avec un $1/255$. . facteur. La plage de cisaillement permet d'appliquer de manière aléatoire des transformations de cisaillement, la plage de zoom permet de zoomer de manière aléatoire à l'intérieur des images, le retournement horizontal permet de retourner aléatoirement la moitié des images horizontalement - pertinent lorsqu'il n'y a aucune hypothèse d'asymétrie horizontale (par exemple, des images du monde réel).

Techniques de prétraitement des données utilisées dans cette étude :

Rescale	$1./255$
Zoom Range	0.2
Horizontal Flip	True

Figure 16 : tableau.

VII.2 Conception de l'architecture du réseau neuronal :

Dans ce projet, nous avons conçu un modèle CNN pour extraire les caractéristiques des images radiographiques pulmonaires et utiliser ces caractéristiques pour détecter si un patient souffre de pneumonie. Dans notre architecture CNN, nous l'avons commencé avec une valeur de filtre inférieure de 16 et l'avons augmentée par couche. Construction du modèle avec une couche de Conv2D suivie d'une couche de Maxpooling.

Nous on a commencé par cette architecture Simple puis au fur et à mesure la modifier c'est- à- dire l'optimiser en utilisant les techniques de d'optimisation telles que : l'ajout des couches de convolution si besoin, les couches de régularisation, les couches de Normalisation (Batch Normalization jusqu'à la rendre une : **architecture CNN optimisée**.

Tanh, ReLU, etc. peuvent être utilisés pour la fonction d'activation, mais ReLU est la plus préférée.

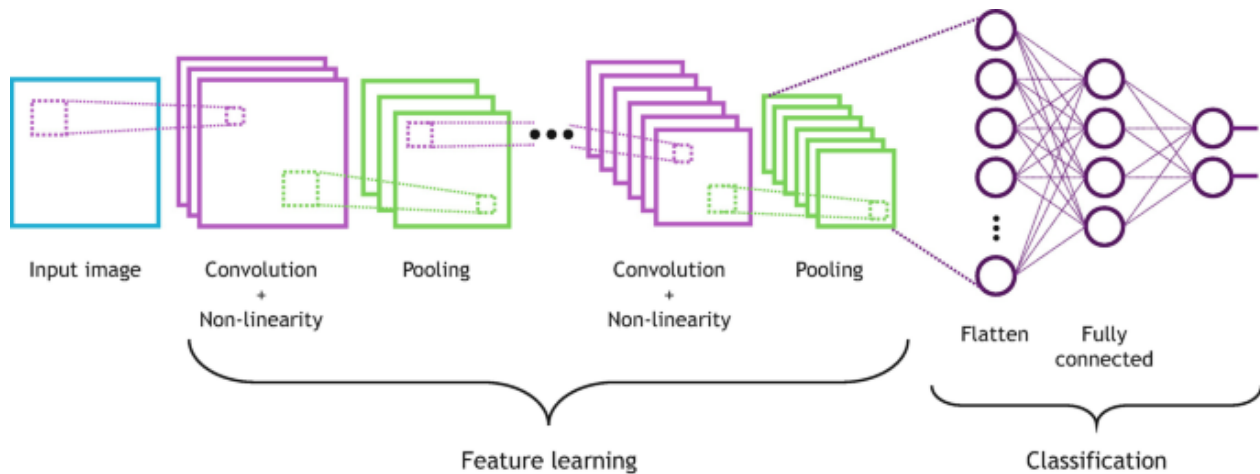


Figure 17: Architecture CNN.

Pour rendre l'architecture optimisée et faire disparaître l'Overfitting (Sur-apprentissage) on doit appliquer les techniques suivantes :

- Plus de couches de convolution.
- Des couches de Normalisation (Batch Normalization)
- Des couches de régularisation (Dropout)

VII.3 Entraînement du modèle et évaluation des performances :

Nous avons développé un modèle de réseau de neurones convolutionnel (CNN) pour détecter la pneumonie dans les images radiographiques. Le processus d'entraînement a été réalisé sur 10 époques avec ajustement automatique du taux d'apprentissage pour optimiser les performances du modèle.

Voici les résultats clés de l'entraînement :

- Précision de l'entraînement : Jusqu'à 95,97%.
- Précision de validation : Jusqu'à 91,78%.
- Perte de validation : Variée entre 0.2232 et 0.2486.

Après l'entraînement, le modèle a été évalué sur un ensemble de test indépendant. Les poids optimaux du modèle ont été chargés pour cette évaluation. Les résultats obtenus sur l'ensemble de test sont : Précision : 92,95% - Perte sur l'ensemble de test : 0.2208.

Ces résultats indiquent que le modèle a une bonne capacité de généralisation et une précision élevée pour la détection de la pneumonie dans les images radiographiques.

VII.4 Présentation des résultats obtenus par le modèle :

Nous avons évalué notre modèle de détection de la pneumonie dans les images radiographiques. Voici un résumé des performances obtenues.

Training and Validation Metrics :




Figure 18 : Graphiques des résultats.

Résultats du test :

- Précision (Accuracy) : 92.94%
- Précision (Precision) : 92.82%
- Rappel (Recall) : 96.15%
- Score F1 : 94.45%

Métriques d'entraînement et de validation :

- Précision d'entraînement et de validation : La précision d'entraînement s'est maintenue autour de 95.96%, tandis que la précision de validation était légèrement plus basse, autour de 91.92%.
- Perte d'entraînement et de validation : La perte d'entraînement a diminué régulièrement, tandis que la perte de validation a fluctué entre 0.125 et 0.250.

Matrice de confusion :

- Normaux prédits comme normaux : 205
- Normaux prédits comme pneumonie : 29

- Pneumonie prédits comme normaux : 15
- Pneumonie prédits comme pneumonie : 375

Confusion Matrix :




Figure 19: Matrice de confusion.

Ces résultats montrent que le modèle a une excellente capacité à détecter la pneumonie, avec des scores de précision et de rappel élevés. La matrice de confusion indique une faible proportion de faux positifs et de faux négatifs, ce qui est un bon indicateur de la robustesse du modèle.

Chapitre VIII :

Conception de l'application

VIII.1 Introduction :

La conception est une étape primordiale dans tout projet informatique, elle doit être traitée avec précision et en détail. Dans ce chapitre, nous allons modéliser notre application web de détection de la pneumonie dans les images radiographiques, et pour ce faire nous avons utilisé le langage UML. Celui-ci permet de bien représenter les aspects statiques et dynamiques de notre projet par la série des diagrammes qu'il offre.

VIII.2 Etude des besoins :

Dans cette section, nous allons identifier et décrire les besoins fonctionnels et non fonctionnels de l'application intranet pour la détection de la pneumonie dans les images radiographiques A l'aide de deep learning :

1.Chargement des images radiographiques :

- Permettre aux utilisateurs de télécharger des images radiographiques à partir de leur appareil.
- Supporter les formats d'image courants (JPEG, PNG, etc.).

2. Prédiction de la pneumonie :

- Utiliser le modèle de CNN pour analyser les images radiographiques et prédire la présence de pneumonie.
- Afficher les résultats de la prédiction à l'utilisateur (présence ou absence de pneumonie).

3.Affichage des résultats :

- Présenter les résultats sous forme de texte et de graphiques, incluant la précision, le rappel, le score F1, etc.
- Afficher une matrice de confusion pour visualiser les performances du modèle.

4. Historique des prédictions :

- Sauvegarder les résultats des prédictions pour un usage ultérieur.
- Permettre aux utilisateurs de consulter l'historique de leurs prédictions.

5. Gestion des utilisateurs :

- Authentification et autorisation des utilisateurs.
- Gestion des comptes utilisateurs (création, modification, suppression).

Besoins non fonctionnels de l'application :

1. Performance :

- Le système doit traiter les images et fournir les résultats de prédiction en temps réel ou en moins de quelques secondes.
- Optimisation des temps de réponse pour le téléchargement et l'affichage des résultats.

2. Sécurité :

- Garantir la confidentialité et la sécurité des données des utilisateurs.
- Utiliser des protocoles de sécurité robustes pour la transmission des données (HTTPS).

3. Scalabilité :

- Capacité à gérer un grand nombre d'utilisateurs simultanément.
- Possibilité de mise à l'échelle horizontale et verticale pour répondre à une augmentation de la demande.

5. Utilisabilité :

- Interface utilisateur intuitive et facile à utiliser pour les utilisateurs non techniques.
- Documentation claire et aide en ligne pour assister les utilisateurs.

7. Maintenance :

- L'application doit être facilement maintenable et évolutive.
- Code bien documenté et suivi des meilleures pratiques de développement.

En résumant, les besoins fonctionnels se concentrent sur les fonctionnalités spécifiques que l'application doit fournir pour détecter la pneumonie à partir des images radiographiques, tandis que les besoins non fonctionnels se concentrent sur les qualités du système qui garantissent son bon fonctionnement, sa sécurité, et son évolutivité.

VIII.3 Diagramme de cas d'utilisation :

Les diagrammes de cas d'utilisation sont généralement appelés diagrammes de comportement utilisés pour décrire un ensemble d'actions que certains systèmes devraient ou peuvent effectuer en collaboration avec un ou plusieurs utilisateurs externes du système. Chaque cas d'utilisation doit fournir un résultat observable et précieux aux acteurs ou autres parties prenantes du système.

La figure montre le diagramme de cas d'utilisation du système. Les acteurs suivants utilisés dans le diagramme de cas d'utilisation sont l'étudiant, l'enseignant, le système et le cloud. Les différents cas d'utilisation utilisés dans le diagramme sont la connexion de l'enseignant, l'affichage des présences, la prise de présence, la capture d'une photo, le traitement de l'image, la prise d'une autre photo :

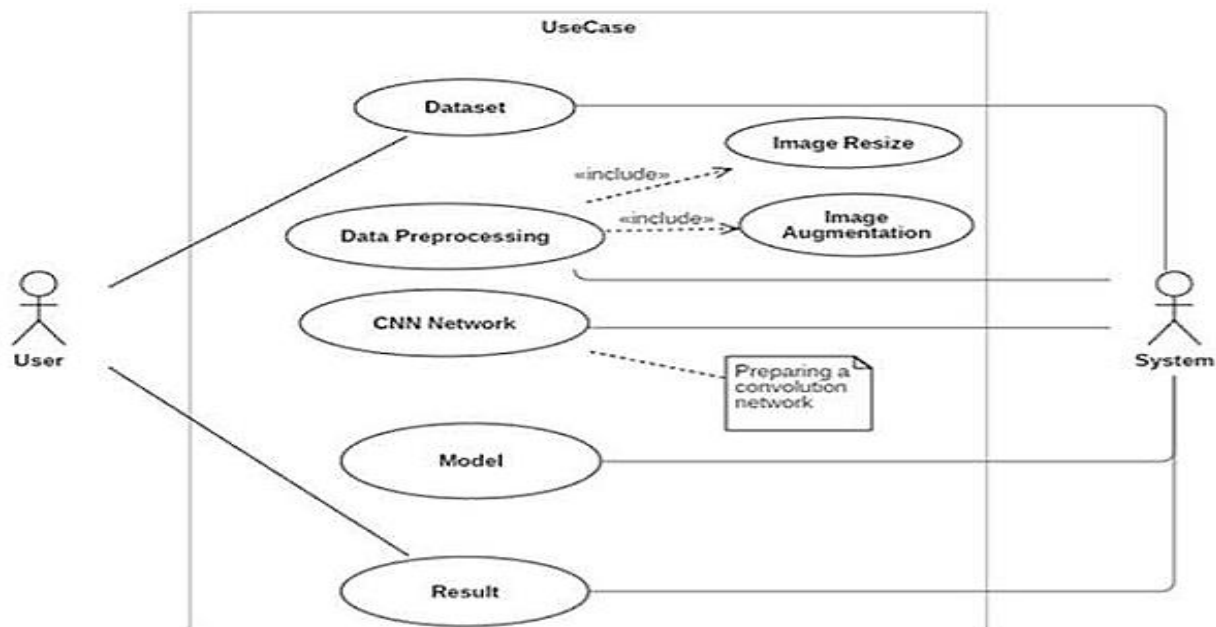


Figure 20: Diagramme de cas d'utilisation.

VIII.4 Diagramme de Séquence :

Les diagrammes de séquence sont parfois appelés diagrammes d'événements ou scénarios d'événements. Un diagramme de séquence montre, sous forme de lignes verticales parallèles (lignes de vie), différents processus ou objets qui vivent simultanément, et, sous forme de flèches horizontales, les messages échangés entre eux, dans l'ordre dans lequel ils se produisent.

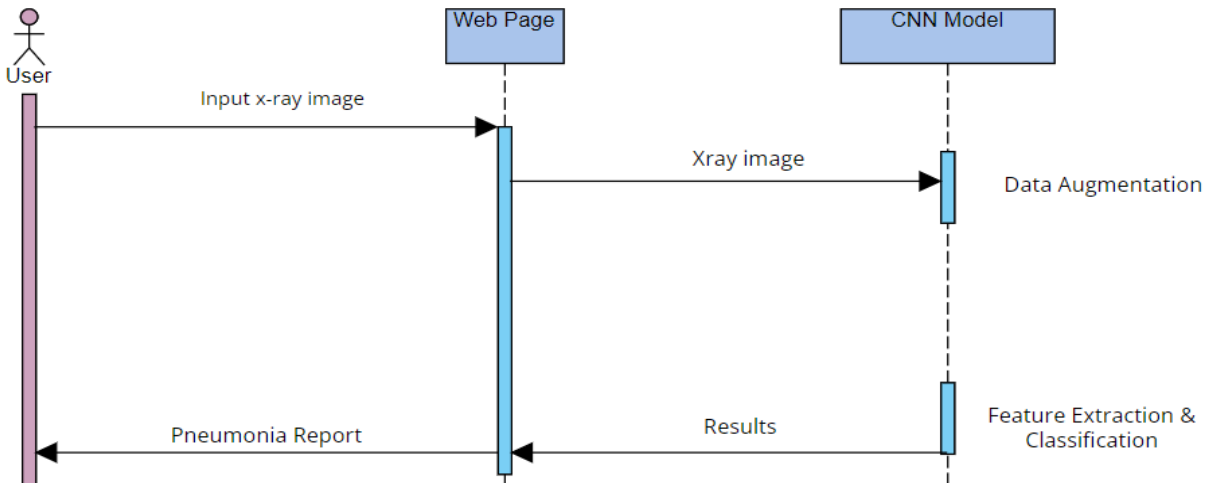


Figure 21: Diagramme de Séquence.

VIII.5 Diagramme d'activité :

Le diagramme d'activité est un autre diagramme important en UML pour décrire les aspects dynamiques du système. Un diagramme d'activités est essentiellement un organigramme représentant le flux d'une activité à une autre. L'activité peut être décrite comme une opération du système. Le flux de contrôle passe d'une opération à une autre.

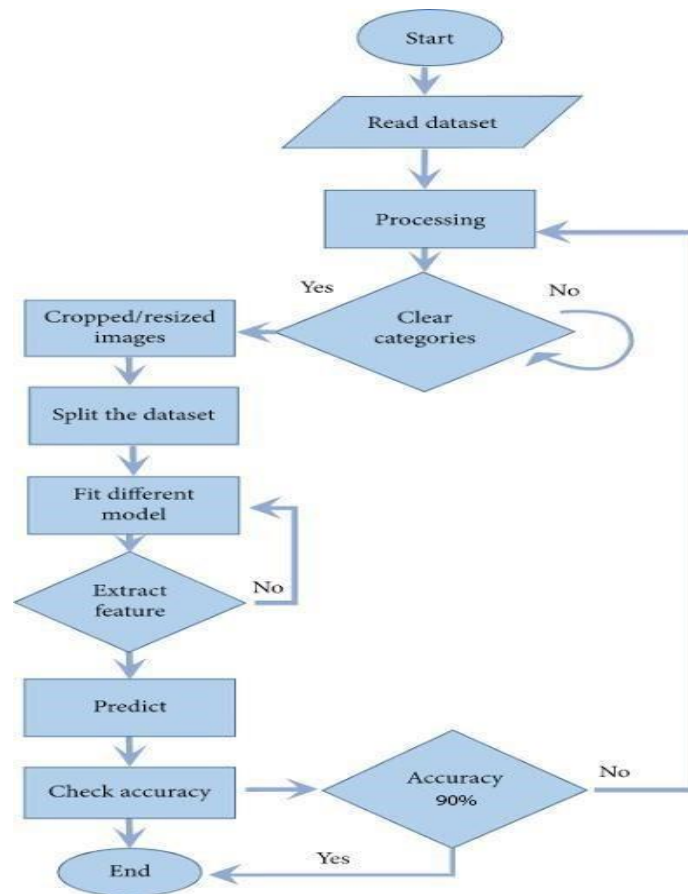


Figure 22: Diagramme d'activité.

VIII.6 Diagramme de classes :

Un diagramme de classes est une illustration des relations et des dépendances du code source entre les classes dans le langage UML (Unified Modeling Language). Dans ce contexte, une classe définit les méthodes et les variables d'un objet, qui est une entité spécifique dans un programme ou l'unité de code représentant cette entité.

La figure 2 montre le diagramme de classes du projet, les différentes classes utilisées dans le diagramme sont utilisateur, étudiant, enseignant, Image, Cloud, Reconnaissance faciale.

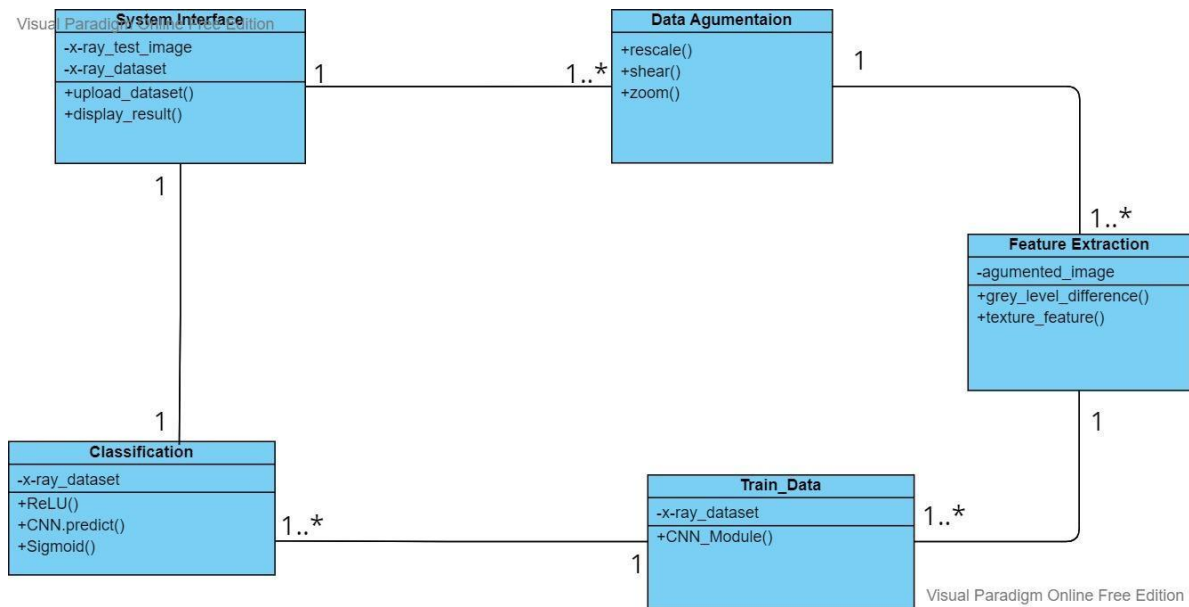


Figure 23: Diagramme de classes.

VIII.7 Conclusion :

En conclusion, nous avons développé une application robuste pour la détection de la pneumonie dans les images radiographiques en utilisant des réseaux de neurones convolutionnels (CNN).

Ces diagrammes nous ont non seulement aidés à structurer et à concevoir l'application de manière méthodique, mais ils ont également servi de guides précieux pour le développement et la communication entre les membres de l'équipe.

L'application, avec ses fonctionnalités bien définies et ses performances élevées, offre une solution pratique et efficace pour aider les professionnels de la santé à diagnostiquer la pneumonie à partir d'images radiographiques. La combinaison des besoins fonctionnels et non fonctionnels garantit que le système est à la fois performant, sécurisé et facile à utiliser. Grâce à cette approche méthodique, nous avons créé une application qui peut avoir un impact significatif sur la détection précoce de la pneumonie, contribuant ainsi à de meilleurs résultats pour les patients.

Chapitre IX :

Réalisation de l'application

IX.1 Introduction :

Dans ce chapitre, nous décrivons la réalisation de l'application destinée à la détection de la pneumonie à partir d'images radiographiques en utilisant des techniques de deep learning, notamment les réseaux de neurones convolutionnels (CNN). Ce processus comprend la conception et l'implémentation des différentes composantes du système, en s'appuyant sur les diagrammes UML pour structurer et organiser le développement. Nous détaillerons les étapes cruciales, de l'entraînement du modèle à l'intégration des fonctionnalités de l'application, tout en assurant que les besoins fonctionnels et non fonctionnels sont satisfaits. Ce chapitre mettra en lumière les choix technologiques, les défis rencontrés et les solutions apportées pour créer une application robuste, performante et facile à utiliser.

IX.2 Environnement du développement :

IX.2.1 Environnement matériel :

Pour développer cette application, Nous avons utilisés un ordinateur portable :

- Un PC DELL avec une puce NVIDIA qui integre un microprocesseur CPU (5 icores) et une carte graphique GPU, Une mémoire vive RAM de 4.00G et un disque dur HDD de 237Go.

IX.2.2 Environnement logiciel :



Figure 24: VSCode.

Visual Studio Code, également connu sous le nom de VSCode, est un éditeur de code source développé par Microsoft qui offre une solution légère et performante pour les développeurs travaillant sur différents langages de programmation et plates-formes. Conçu pour être à la fois puissant et facile à utiliser, VSCode combine des fonctionnalités essentielles telles que l'autocomplétion intelligente, le support du contrôle de version et le débogage, tout en permettant aux utilisateurs de personnaliser leur environnement grâce à une vaste gamme d'extensions.



Figure 25: Google Colab.

Google Colab : est une plateforme gratuite de Google permettant d'écrire et d'exécuter du code Python directement dans le navigateur. Elle est particulièrement utile pour les projets de machine learning et de deep learning grâce à plusieurs avantages. Tout d'abord, Colab offre un accès gratuit aux GPU et TPU, accélérant considérablement les calculs intensifs nécessaires pour l'entraînement des modèles. Ensuite, Colab est bien intégré avec les services Google comme Google Drive, facilitant la gestion et le stockage des données. De plus, il permet d'installer facilement des bibliothèques supplémentaires via pip.

Colab est aussi conçu pour faciliter la collaboration. Les utilisateurs peuvent partager leurs notebooks, permettant ainsi un travail collaboratif et en temps réel sur le même code. La plateforme est simple à utiliser, sans besoin de configuration locale complexe, ce qui la rend accessible même pour les débutants en programmation et en machine learning.

Front-end :

HTML :



Figure 26: HTML.

HTML (HyperText Markup Language) est le langage standard utilisé pour créer des pages web. Il permet de structurer et de présenter le contenu sur Internet. HTML utilise des balises pour définir différents éléments comme les titres, les paragraphes, les liens, les images, et bien d'autres. Chaque balise a un rôle spécifique et aide à organiser le contenu de manière logique et hiérarchique.

L'un des principaux avantages de HTML est sa simplicité et son accessibilité. Même avec peu de connaissances en programmation, il est possible de créer une page web de base. HTML est également extensible et fonctionne bien avec d'autres technologies web comme CSS (Cascading Style Sheets) pour le style et la présentation, et JavaScript pour le comportement et les interactions.

HTML est constamment mis à jour pour s'adapter aux nouvelles exigences du web moderne. La version actuelle, HTML5, apporte de nombreuses améliorations, y compris de nouvelles balises sémantiques, des

capacités multimédias sans besoin de plugins supplémentaires, et des fonctionnalités avancées pour le développement web interactif.

En résumé, HTML est un langage essentiel pour le développement web, fournissant la structure de base des pages web et permettant leur mise en forme et leur interactivité grâce à des technologies complémentaires.

CSS :



Figure 27: CSS.

CSS (Cascading Style Sheets) est un langage utilisé pour décrire la présentation et la mise en forme des documents HTML. Il permet de séparer le contenu de la présentation, ce qui facilite la maintenance et la gestion des sites web. Avec CSS, il est possible de contrôler la mise en page, les couleurs, les polices, les marges, les espacements, et bien d'autres aspects visuels des pages web.

L'un des principaux avantages de CSS est sa capacité à appliquer des styles de manière cohérente à travers plusieurs pages d'un site web. En utilisant des feuilles de style externes, un seul fichier CSS peut être lié à plusieurs documents HTML, ce qui simplifie les modifications globales et assure une uniformité visuelle. CSS permet également d'adapter le design des pages web pour différents appareils et tailles d'écran grâce aux media queries, rendant les sites web réactifs et accessibles sur mobiles.

CSS est un langage puissant et flexible. Il offre une grande variété de sélecteurs et de propriétés qui permettent de cibler précisément les éléments HTML et de définir des styles complexes. Les dernières versions de CSS, comme CSS3, ont introduit de nombreuses nouvelles fonctionnalités, telles que les animations, les transitions, les transformations 3D et les grilles de mise en page, qui enrichissent encore plus les possibilités de design web.

JAVASCRIPT :



Figure 28: JAVASCRIPT.

JavaScript (JS) est un langage de programmation dynamique utilisé principalement pour ajouter des fonctionnalités interactives aux pages web. Contrairement à HTML qui structure le contenu et à CSS qui

le style, JavaScript permet de manipuler et de contrôler les éléments web en temps réel, créant ainsi des expériences utilisateur plus engageantes et interactives.

L'un des principaux avantages de JavaScript est sa capacité à être exécuté directement dans le navigateur web, ce qui permet d'apporter des interactions instantanées sans nécessiter de rechargement de la page. Cela inclut des fonctionnalités telles que les formulaires interactifs, les menus déroulants, les animations, les jeux et les mises à jour dynamiques de contenu.

JavaScript est également très versatile et peut être utilisé pour bien plus que les simples interactions sur les pages web. Avec l'avènement de Node.js, JavaScript peut être utilisé pour le développement côté serveur, permettant de créer des applications web complètes en utilisant un seul langage. De plus, des frameworks et bibliothèques populaires comme React, Angular et Vue.js ont été développés pour faciliter et structurer le développement d'applications web complexes.

Back-end :

FLASK :



Figure 29: Flask.

Flask est un micro-framework web léger en Python, conçu pour être simple et flexible. Contrairement à certains frameworks plus lourds, Flask n'impose pas de structure spécifique ni de dépendances excessives, ce qui en fait un excellent choix pour les développeurs qui veulent construire des applications web de manière rapide et efficace, tout en gardant un contrôle total sur les composants utilisés.

L'un des principaux avantages de Flask est sa simplicité et sa facilité d'utilisation. Il est facile à apprendre et à utiliser, ce qui le rend idéal pour les débutants en développement web ainsi que pour les projets plus petits ou moyens. Flask offre les fonctionnalités essentielles nécessaires pour créer des applications web, telles que le routage des URL, la gestion des requêtes et des réponses, et les sessions utilisateur.

Flask est également très extensible. Il peut être facilement étendu à l'aide de modules et de bibliothèques complémentaires pour ajouter des fonctionnalités plus avancées, telles que la gestion des bases de données avec SQLAlchemy, l'authentification des utilisateurs, et l'intégration de modèles HTML avec Jinja2. Cette modularité permet aux développeurs de n'utiliser que les outils dont ils ont besoin, ce qui maintient l'application légère et performante.

TENSORFLOW :



Figure 30: Tensorflow.

TensorFlow est une bibliothèque open-source développée par Google pour le calcul numérique et l'apprentissage automatique. Elle est particulièrement utilisée pour le développement et l'entraînement de modèles de machine learning et de deep learning grâce à sa flexibilité et sa capacité à traiter de grandes quantités de données.

L'un des principaux avantages de TensorFlow est sa capacité à fonctionner sur différentes plateformes, y compris les ordinateurs de bureau, les serveurs et les appareils mobiles. Cela permet de déployer des modèles de machine learning sur divers environnements, facilitant ainsi leur intégration dans des applications réelles. TensorFlow offre également un support robuste pour le calcul distribué, ce qui permet d'accélérer l'entraînement des modèles sur des clusters de machines.

TensorFlow est extrêmement flexible grâce à son architecture modulaire. Il permet aux développeurs de construire et d'entraîner des réseaux de neurones complexes à l'aide de son API haut niveau (Keras) ou d'accéder à des opérations bas niveau pour une personnalisation avancée. Cette flexibilité le rend adapté à une large gamme d'applications, allant de la vision par ordinateur et du traitement du langage naturel à la reconnaissance vocale et à la prédiction de séries temporelles.

IX.3 Interfaces Graphiques:

- Page de connexion :

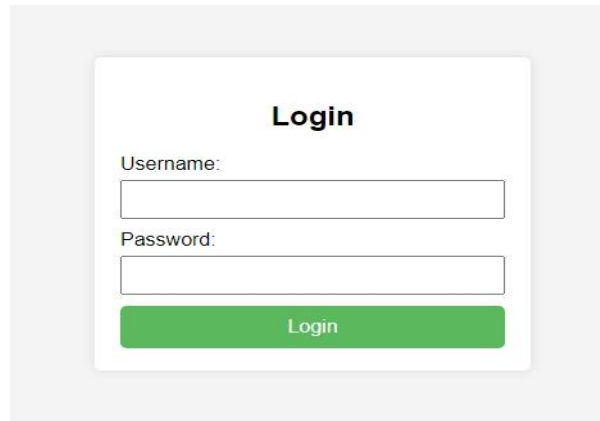
A login form titled "Login" centered on a light gray background. The form is a white rectangle with a thin border. It contains two input fields: "Username:" and "Password:", each with a corresponding text box. Below the password field is a green button with the text "Login" in white.

Figure 31: page de connexion.

- Page principale :





Figure 32: page principale.

- Page du téléchargement de l'image :

Upload Files
Upload images for prediction. only Images are allowed.



Drag & Drop your files here
OR

Browse Files

Predict

Figure 33: télécharger des images.

•Page du résultat :

Downloaded Image :



Ce patient est normal : résultat négatif.

Figure 34:page résultat.

Conclusion Générale :

En conclusion, cette application de détection de la pneumonie dans les images radiographiques à l'aide de réseaux de neurones convolutifs (CNN) représente une avancée significative dans le domaine du diagnostic médical assisté par l'intelligence artificielle. En automatisant l'analyse des radiographies, elle améliore la précision et la rapidité du diagnostic, tout en offrant un outil précieux aux professionnels de santé. L'implémentation rigoureuse de fonctionnalités telles que le téléchargement sécurisé des images, le prétraitement optimisé, et la génération de rapports détaillés garantit une utilisation efficace et fiable. Cette application démontre le potentiel des technologies de deep learning pour transformer les pratiques médicales et améliorer les soins aux patients.

Références :

<file:///C:/Users/dell/Desktop/plan/pdf/pense-bete-apprentissage-non-supervise.pdf>

<file:///C:/Users/dell/Desktop/plan/pdf/pense-bete-apprentissage-profond.pdf>

<file:///C:/Users/dell/Desktop/plan/pdf/pense-bete-apprentissage-supervise.pdf>

<https://arxiv.org/list/cs.LG/recent>

<file:///C:/Users/dell/Desktop/dossiers/1015-4583-1-PB.pdf>

<file:///C:/Users/dell/Desktop/dossiers/2204.03618.pdf>

[file:///C:/Users/dell/Desktop/dossiers/Data Analyticsfor%20NLP%20AI.pdf](file:///C:/Users/dell/Desktop/dossiers/Data_Analyticsfor%20NLP%20AI.pdf)

<https://chatgpt.com/>

https://fr.wikipedia.org/wiki/Wikip%C3%A9dia:Accueil_principal